Implementazione di una Rete Convoluzionale in CUDA

Michele Valsesia

Nicholas Aspes

Anno accademico 2018/2019

Introduzione

Obiettivi

- Descrivere l'architettura ed il funzionamento di una *Rete Neurale Semplice* e di una *Convoluzionale*

Introduzione

Obiettivi

- Descrivere l'architettura ed il funzionamento di una *Rete Neurale Semplice* e di una *Convoluzionale*

- Motivare le differenti scelte implementative adottate durante lo svolgimento del progetto

Introduzione

Obiettivi

- Descrivere l'architettura ed il funzionamento di una *Rete Neurale Semplice* e di una *Convoluzionale*
- Motivare le differenti scelte implementative adottate durante lo svolgimento del progetto
- Valutare l'accuratezza e lo speedup della rete rispetto ad una implementazione di tipo sequenziale

Reti Neurali

Reti Neurali

Scopo

- Le *Reti Neurali* vengono principalmente usate per la classificazione di immagini

Reti Neurali

Scopo

- Le *Reti Neurali* vengono principalmente usate per la classificazione di immagini

- Il processo di classificazione consiste nell'assegnare ad un immagine un'etichetta che identifichi nel miglior modo possibile il suo contenuto semantico

Reti Neurali

Scopo

- Le *Reti Neurali* vengono principalmente usate per la classificazione di immagini
- Il processo di classificazione consiste nell'assegnare ad un immagine un'etichetta che identifichi nel miglior modo possibile il suo contenuto semantico
- Un'etichetta è meglio conosciuta con il nome di *classe*

Reti Neurali

Scopo

- Le *Reti Neurali* vengono principalmente usate per la classificazione di immagini
- Il processo di classificazione consiste nell'assegnare ad un immagine un'etichetta che identifichi nel miglior modo possibile il suo contenuto semantico
- Un'etichetta è meglio conosciuta con il nome di *classe*
- Le reti neurali ricevono in input un'immagine e restituiscono in output la relativa classe

Reti Neurali

Funzionamento

- Una rete neurale deve *apprendere* come assegnare correttamente alle immagini le varie classi

Reti Neurali

Funzionamento

- Una rete neurale deve *apprendere* come assegnare correttamente alle immagini le varie classi
- Un *esempio* è una coppia (immagine, etichetta)

Reti Neurali

Funzionamento

- Una rete neurale deve *apprendere* come assegnare correttamente alle immagini le varie classi
- Un *esempio* è una coppia (immagine, etichetta)
- Un esempio viene creato da un team di persone che valuta il contenuto semantico di un immagine e le associa l'etichetta più adatta

Reti Neurali

Funzionamento

- Una rete neurale deve *apprendere* come assegnare correttamente alle immagini le varie classi
- Un *esempio* è una coppia (immagine, etichetta)
- Un esempio viene creato da un team di persone che valuta il contenuto semantico di un immagine e le associa l'etichetta più adatta
- Il *training set* ed il *test set* sono insiemi di esempi

Reti Neurali

Funzionamento

- Una rete neurale deve *apprendere* come assegnare correttamente alle immagini le varie classi
- Un *esempio* è una coppia (immagine, etichetta)
- Un esempio viene creato da un team di persone che valuta il contenuto semantico di un immagine e le associa l'etichetta più adatta
- Il *training set* ed il *test set* sono insiemi di esempi
- Il training set viene usato per l'addestramento (training) della rete

Reti Neurali

Funzionamento

- Una rete neurale deve *apprendere* come assegnare correttamente alle immagini le varie classi
- Un *esempio* è una coppia (immagine, etichetta)
- Un esempio viene creato da un team di persone che valuta il contenuto semantico di un immagine e le associa l'etichetta più adatta
- Il *training set* ed il *test set* sono insiemi di esempi
- Il training set viene usato per l'addestramento (training) della rete
- Il test set serve a controllare che la rete abbia imparato a discriminare correttamente le immagini

Reti Neurali

Training

- Per ognuno degli esempi del training set

Reti Neurali

Training

- Per ognuno degli esempi del training set
  - La rete assegna all'immagine corrente la classe che meglio rappresenta il suo contenuto semantico

Reti Neurali

Training

- Per ognuno degli esempi del training set
  - La rete assegna all'immagine corrente la classe che meglio rappresenta il suo contenuto semantico
  - Se la classe di output è diversa dall'etichetta dell'esempio, la rete corregge i suoi parametri interni e passa all'immagine successiva

Reti Neurali

Testing

- L'*accuratezza* della rete è data dal rapporto tra il numero di esempi classificati correttamente e la cardinalità del test set

Reti Neurali

Testing

- L'*accuratezza* della rete è data dal rapporto tra il numero di esempi classificati correttamente e la cardinalità del test set

- Per ognuno degli esempi del test set

Reti Neurali

Testing

- L'*accuratezza* della rete è data dal rapporto tra il numero di esempi classificati correttamente e la cardinalità del test set

- Per ognuno degli esempi del test set

  - La rete assegna all'immagine corrente la classe che meglio rappresenta il suo contenuto semantico

Reti Neurali

Testing

- L'*accuratezza* della rete è data dal rapporto tra il numero di esempi classificati correttamente e la cardinalità del test set

- Per ognuno degli esempi del test set

  - La rete assegna all'immagine corrente la classe che meglio rappresenta il suo contenuto semantico

  - Per sapere il numero di immagini classificate correttamente dalla rete è necessario definire un contatore

Reti Neurali

Testing

- L'*accuratezza* della rete è data dal rapporto tra il numero di esempi classificati correttamente e la cardinalità del test set

- Per ognuno degli esempi del test set

  - La rete assegna all'immagine corrente la classe che meglio rappresenta il suo contenuto semantico

  - Per sapere il numero di immagini classificate correttamente dalla rete è necessario definire un contatore

  - Il contatore viene incrementato quando l'output prodotto è uguale all'etichetta dell'esempio considerato

Reti Neurali

Significato Biologico

- Le *Reti Neurali* nascono con lo scopo di modellare una rete neurale biologica

Reti Neurali

Significato Biologico

- Le *Reti Neurali* nascono con lo scopo di modellare una rete neurale biologica

- Una rete neurale biologica si compone di unità cellulari di base: i *neuroni*

Reti Neurali

Significato Biologico

- Le *Reti Neurali* nascono con lo scopo di modellare una rete neurale biologica
- Una rete neurale biologica si compone di unità cellulari di base: i *neuroni*
- I neuroni sono collegati tra loro per mezzo di specifiche giunture chiamate *sinapsi*

Reti Neurali

Neurone

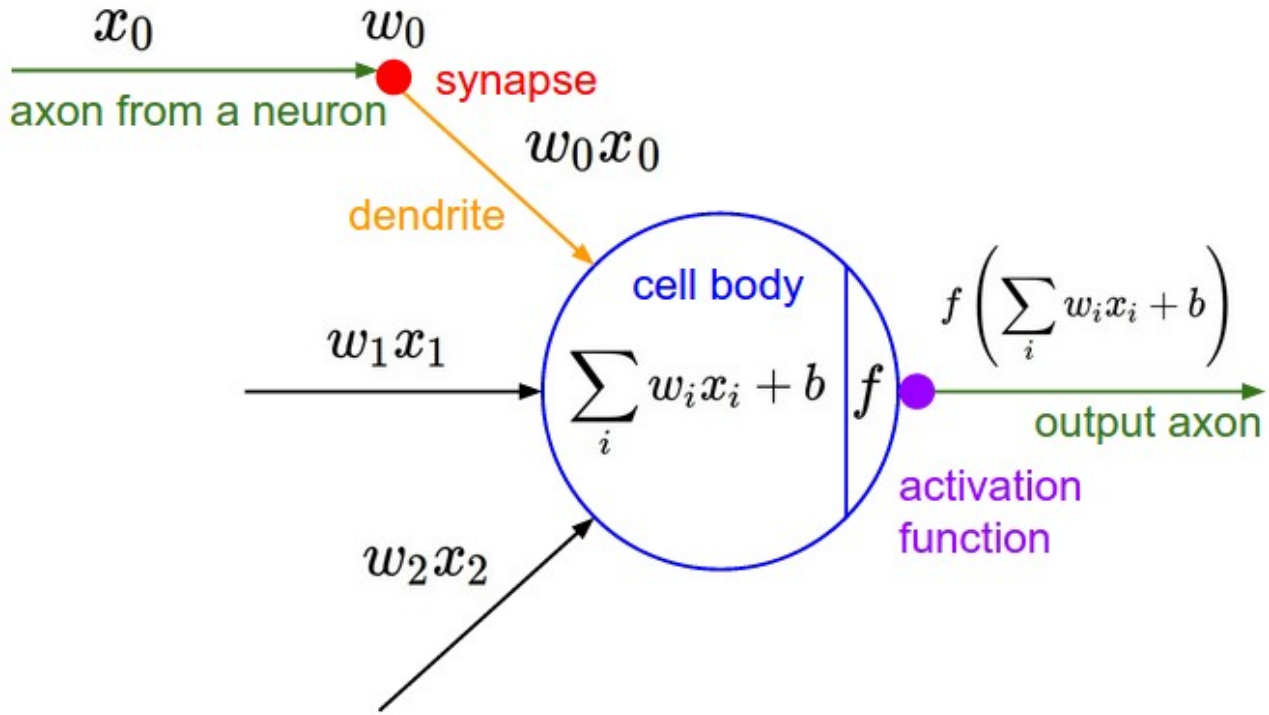

Modello matematico di un neurone

Reti Neurali

Funzionamento Neurone

- Attraverso un meccanismo di eccitazione ed inibizione i pesi sinaptici controllano quanto un neurone sia influenzato dagli altri

Reti Neurali

Funzionamento Neurone

- Attraverso un meccanismo di eccitazione ed inibizione i pesi sinaptici controllano quanto un neurone sia influenzato dagli altri

- I segnali in ingresso al neurone vengono pesati dalle differenti sinapsi, trasportati dai dendriti all'interno del corpo cellulare e sommati tra loro

Reti Neurali

Funzionamento Neurone

- Attraverso un meccanismo di eccitazione ed inibizione i pesi sinaptici controllano quanto un neurone sia influenzato dagli altri
- I segnali in ingresso al neurone vengono pesati dalle differenti sinapsi, trasportati dai dendriti all'interno del corpo cellulare e sommati tra loro
- Quando la somma supera una certa soglia, il neurone *spara* un segnale lungo l'assone

Reti Neurali

Funzionamento Neurone

- Attraverso un meccanismo di eccitazione ed inibizione i pesi sinaptici controllano quanto un neurone sia influenzato dagli altri
- I segnali in ingresso al neurone vengono pesati dalle differenti sinapsi, trasportati dai dendriti all'interno del corpo cellulare e sommati tra loro
- Quando la somma supera una certa soglia, il neurone *spara* un segnale lungo l'assone
- La *frequenza di sparo* del neurone viene modellata con una funzione di attivazione f

Reti Neurali

Funzioni di Attivazione

Definizione

Una *funzione di attivazione* è una funzione matematica non lineare usata per modellare l'output di un neurone. L'input è dato dalla somma pesata dei segnali in ingresso al neurone

Reti Neurali

Funzioni di Attivazione

Definizione

Una *funzione di attivazione* è una funzione matematica non lineare usata per modellare l'output di un neurone. L'input è dato dalla somma pesata dei segnali in ingresso al neurone

- *Rectifier Linear Unit*

Reti Neurali

Funzioni di Attivazione

Definizione

Una *funzione di attivazione* è una funzione matematica non lineare usata per modellare l'output di un neurone. L'input è dato dalla somma pesata dei segnali in ingresso al neurone

- *Rectifier Linear Unit*
- *Sigmoide*

Reti Neurali

Funzioni di Attivazione

Definizione

Una *funzione di attivazione* è una funzione matematica non lineare usata per modellare l'output di un neurone. L'input è dato dalla somma pesata dei segnali in ingresso al neurone

- *Rectifier Linear Unit*
- *Sigmoide*
- *Tangente Iperbolica*

Reti Neurali

Funzioni di Attivazione

Definizione

Una *funzione di attivazione* è una funzione matematica non lineare usata per modellare l'output di un neurone. L'input è dato dalla somma pesata dei segnali in ingresso al neurone

- *Rectifier Linear Unit*
- *Sigmoide*
- *Tangente Iperbolica*
- *Softplus*

Reti Neurali

Rectifier Linear Unit

Definizione

La *Rectifier Linear Unit (ReLU)* $r : \mathbb{R} \to [0, +\infty)$ è definita come $r(x) = \max(0, x)$

Reti Neurali

Rectifier Linear Unit

Definizione

La *Rectifier Linear Unit (ReLU)* $r : \mathbb{R} \to [0, +\infty)$ è definita come $r(x) = \max(0, x)$

- Si differenzia da una funzione di tipo lineare per metà del suo dominio in quanto $\forall x < 0, max(0, x) = 0$

Reti Neurali

Rectifier Linear Unit

Definizione

La *Rectifier Linear Unit (ReLU)* $r : \mathbb{R} \to [0, +\infty)$ è definita come $r(x) = \max(0, x)$

- Si differenzia da una funzione di tipo lineare per metà del suo dominio in quanto $\forall x < 0, max(0, x) = 0$
- Presenta un punto di discontinuità in $x = 0$

Reti Neurali

Rectifier Linear Unit

Definizione

La *Rectifier Linear Unit (ReLU)* $r : \mathbb{R} \to [0, +\infty)$ è definita come $r(x) = \max(0, x)$

- Si differenzia da una funzione di tipo lineare per metà del suo dominio in quanto $\forall x < 0, max(0, x) = 0$
- Presenta un punto di discontinuità in $x = 0$
- La sua derivata è pari a $r'(x) = \mathbb{1}(x \geq 0)$

Reti Neurali

Rectifier Linear Unit

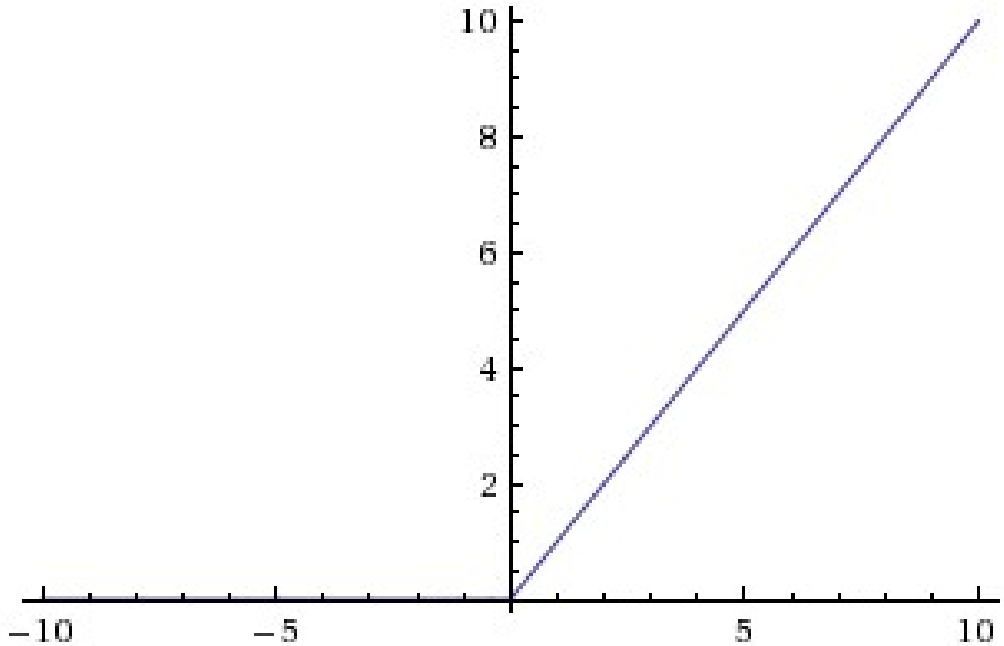

Rappresentazione grafica ReLU

Reti Neurali

Sigmoide

Definizione

La *Sigmoide* $\sigma : \mathbb{R} \to [0, 1]$ è definita come $\sigma(x) = \frac{1}{(1+e^{-x})}$

Reti Neurali

Sigmoide

Definizione

La *Sigmoide* $\sigma : \mathbb{R} \to [0, 1]$ è definita come $\sigma(x) = \frac{1}{(1+e^{-x})}$

- Per elevati valori negativi di input la sigmoide restituisce 0: il neurone non spara affatto

Reti Neurali

Sigmoide

Definizione

La *Sigmoide* $\sigma : \mathbb{R} \to [0, 1]$ è definita come $\sigma(x) = \frac{1}{(1+e^{-x})}$

- Per elevati valori negativi di input la sigmoide restituisce 0: il neurone non spara affatto
- Per elevati valori positivi la sigmoide restituisce 1: il neurone satura e spara con frequenza di sparo pari a 1

Reti Neurali

Sigmoide

Definizione

La *Sigmoide* $\sigma : \mathbb{R} \to [0, 1]$ è definita come $\sigma(x) = \frac{1}{(1+e^{-x})}$

- Per elevati valori negativi di input la sigmoide restituisce 0: il neurone non spara affatto
- Per elevati valori positivi la sigmoide restituisce 1: il neurone satura e spara con frequenza di sparo pari a 1
- La sua derivata è uguale a $\sigma'(x) = \sigma(x)(1 - \sigma(x))$

Reti Neurali

Sigmoide

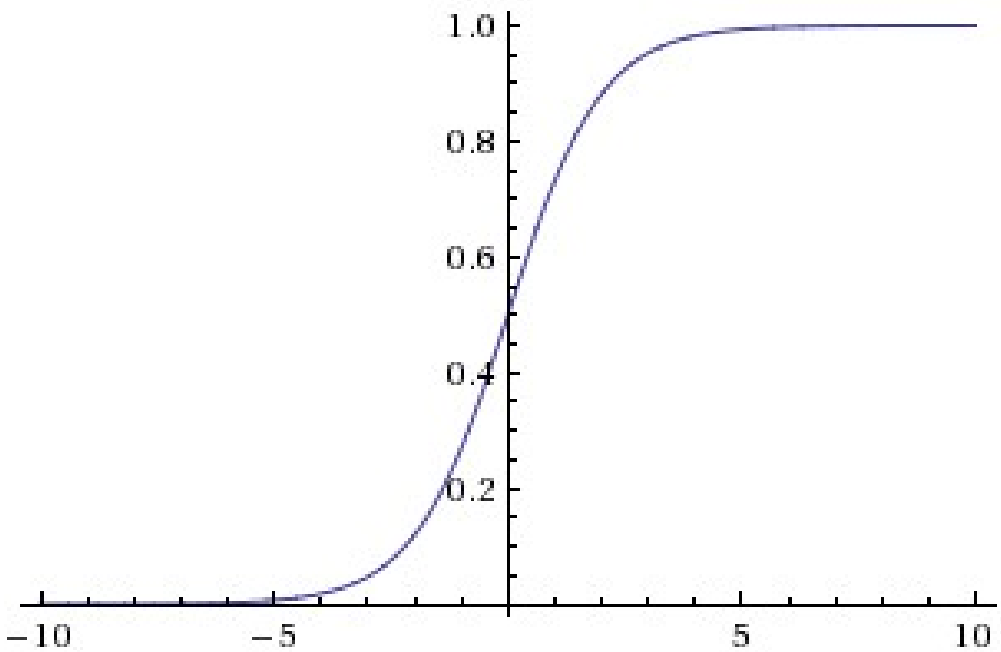

Rappresentazione grafica Sigmoide

Reti Neurali

Tangente Iperbolica

Definizione

La *Tangente Iperbolica* $\tanh : \mathbb{R} \to [-1, 1]$ è definita come $\tanh(x) = 2\sigma(2x) - 1$

Reti Neurali

Tangente Iperbolica

Definizione

La *Tangente Iperbolica* $\tanh : \mathbb{R} \to [-1, 1]$ è definita come $\tanh(x) = 2\sigma(2x) - 1$

- La tangente iperbolica è una sigmoide scalata

Reti Neurali

Tangente Iperbolica

Definizione

La *Tangente Iperbolica* $\tanh : \mathbb{R} \to [-1, 1]$ è definita come $\tanh(x) = 2\sigma(2x) - 1$

- La tangente iperbolica è una sigmoide scalata
- A differenza della sigmoide passa dall'origine per $x = 0$

Reti Neurali

Tangente Iperbolica

Definizione

La *Tangente Iperbolica* $\tanh : \mathbb{R} \to [-1, 1]$ è definita come $\tanh(x) = 2\sigma(2x) - 1$

- La tangente iperbolica è una sigmoide scalata
- A differenza della sigmoide passa dall'origine per $x = 0$
- La sua derivata è uguale a $\tanh'(x) = 1 - \tanh^2(x)$

Reti Neurali

Tangente Iperbolica

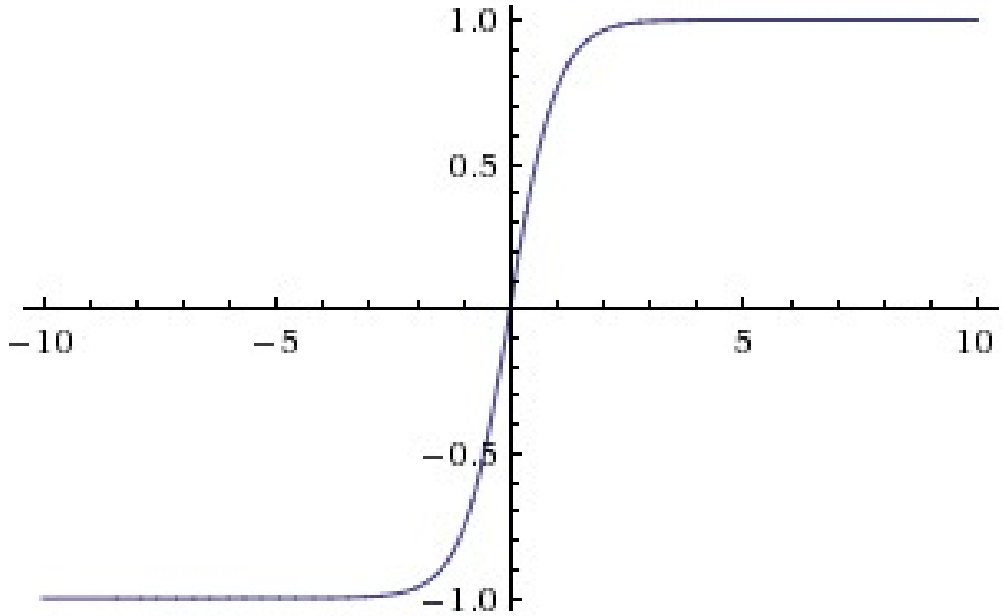

Rappresentazione grafica Tangente Iperbolica

Reti Neurali

Softplus

Definizione

La *Softplus* $s : \mathbb{R} \to (0, +\infty)$ è definita come $s(x) = \log(1 + e^x)$

Reti Neurali

Softplus

Definizione

La *Softplus* $s : \mathbb{R} \to (0, +\infty)$ è definita come $s(x) = \log(1 + e^x)$

- La softplus è una buona approssimazione della ReLU

Reti Neurali

Softplus

Definizione

La *Softplus* $s : \mathbb{R} \to (0, +\infty)$ è definita come $s(x) = \log(1 + e^x)$

- La softplus è una buona approssimazione della ReLU
- Viene solitamente usata per sostituire la ReLU perché non presenta punti di discontinuità

Reti Neurali

Softplus

Definizione

La *Softplus* $s : \mathbb{R} \to (0, +\infty)$ è definita come $s(x) = \log(1 + e^x)$

- La softplus è una buona approssimazione della ReLU
- Viene solitamente usata per sostituire la ReLU perché non presenta punti di discontinuità
- La sua derivata è uguale a $s'(x) = \frac{1}{(1+e^{-x})} = \sigma(x)$

Reti Neurali

Softplus

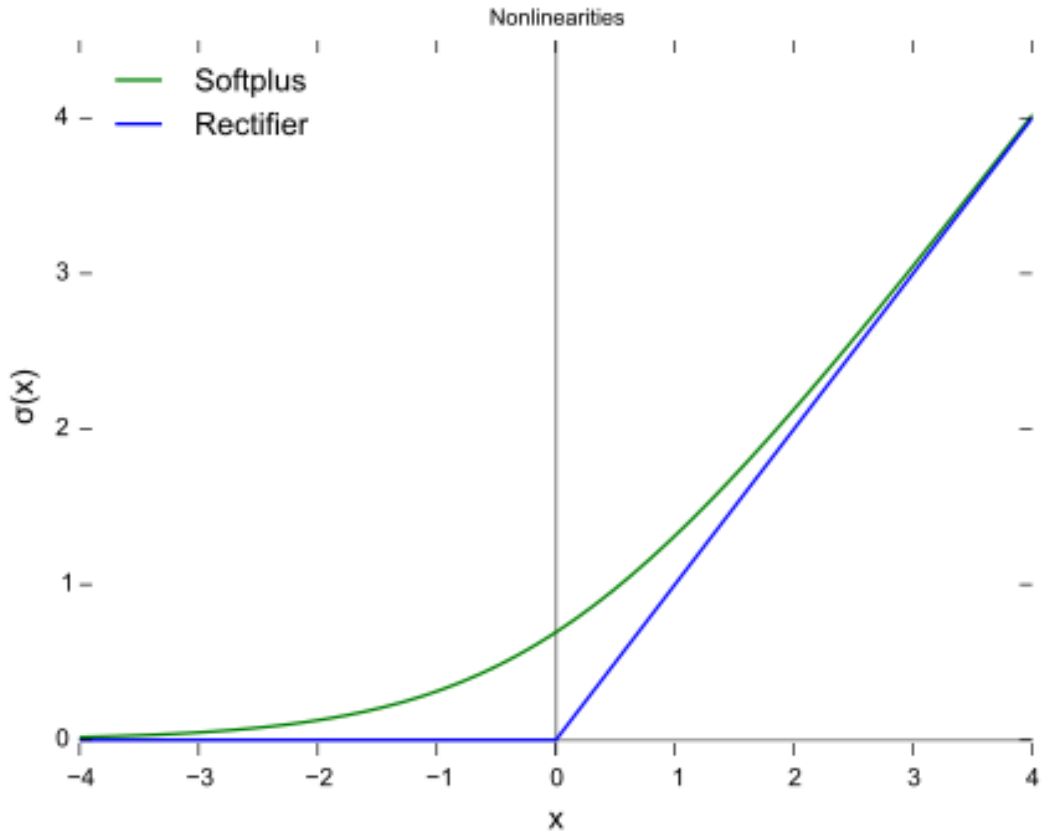

Confronto grafico tra ReLU e Softplus

Reti Neurali

Rete Neurale

Definizione

Una *Rete Neurale* è composta da un certo numero di neuroni organizzati in insiemi distinti chiamati *livelli* o *layer*

Reti Neurali

Rete Neurale

Definizione

Una *Rete Neurale* è composta da un certo numero di neuroni organizzati in insiemi distinti chiamati *livelli* o *layer*

- I livelli sono connessi tra loro e sono posizionati uno di seguito all'altro in modo da formare una sequenza

Reti Neurali

Rete Neurale

Definizione

Una *Rete Neurale* è composta da un certo numero di neuroni organizzati in insiemi distinti chiamati *livelli* o *layer*

- I livelli sono connessi tra loro e sono posizionati uno di seguito all'altro in modo da formare una sequenza

- I livelli intermedi prendono il nome di *hidden*

Reti Neurali

Rete Neurale

Definizione

Una *Rete Neurale* è composta da un certo numero di neuroni organizzati in insiemi distinti chiamati *livelli* o *layer*

- I livelli sono connessi tra loro e sono posizionati uno di seguito all'altro in modo da formare una sequenza
- I livelli intermedi prendono il nome di *hidden*
- L'output dei neuroni di un livello diventano l'input dei neuroni del livello successivo

Reti Neurali

Rete Neurale

- Quando si effettua il conteggio dei livelli di una rete non si considera il livello di input

Reti Neurali

Rete Neurale

- Quando si effettua il conteggio dei livelli di una rete non si considera il livello di input

- Una rete a *singolo livello* non presenta livelli hidden

Reti Neurali

Rete Neurale

- Quando si effettua il conteggio dei livelli di una rete non si considera il livello di input
- Una rete a *singolo livello* non presenta livelli hidden
- Per determinare la grandezza di una rete ci si concentra sul numero di neuroni e sui relativi pesi ad essi associati

Reti Neurali

Livello Fully-Connected

Definizione

Un livello è di tipo *Fully-Connected* quando i neuroni che lo compongono sono completamente connessi ai neuroni del livello successivo e non sono collegati tra loro internamente

Reti Neurali

Livello Fully-Connected

Definizione

Un livello è di tipo *Fully-Connected* quando i neuroni che lo compongono sono completamente connessi ai neuroni del livello successivo e non sono collegati tra loro internamente

- I pesi dei neuroni di ciascun livello sono salvati all'interno di matrici

Reti Neurali

Livello Fully-Connected

Definizione

Un livello è di tipo *Fully-Connected* quando i neuroni che lo compongono sono completamente connessi ai neuroni del livello successivo e non sono collegati tra loro internamente

- I pesi dei neuroni di ciascun livello sono salvati all'interno di matrici
- Le righe di una matrice identificano i neuroni del livello mentre le colonne contengono i pesi di ciascun neurone

Reti Neurali

Livello Fully-Connected

Definizione

Un livello è di tipo *Fully-Connected* quando i neuroni che lo compongono sono completamente connessi ai neuroni del livello successivo e non sono collegati tra loro internamente

- I pesi dei neuroni di ciascun livello sono salvati all'interno di matrici
- Le righe di una matrice identificano i neuroni del livello mentre le colonne contengono i pesi di ciascun neurone
- La struttura a livelli di una rete neurale permette di sfruttare le potenzialità del calcolo matriciale

Reti Neurali

Livello Fully-Connected

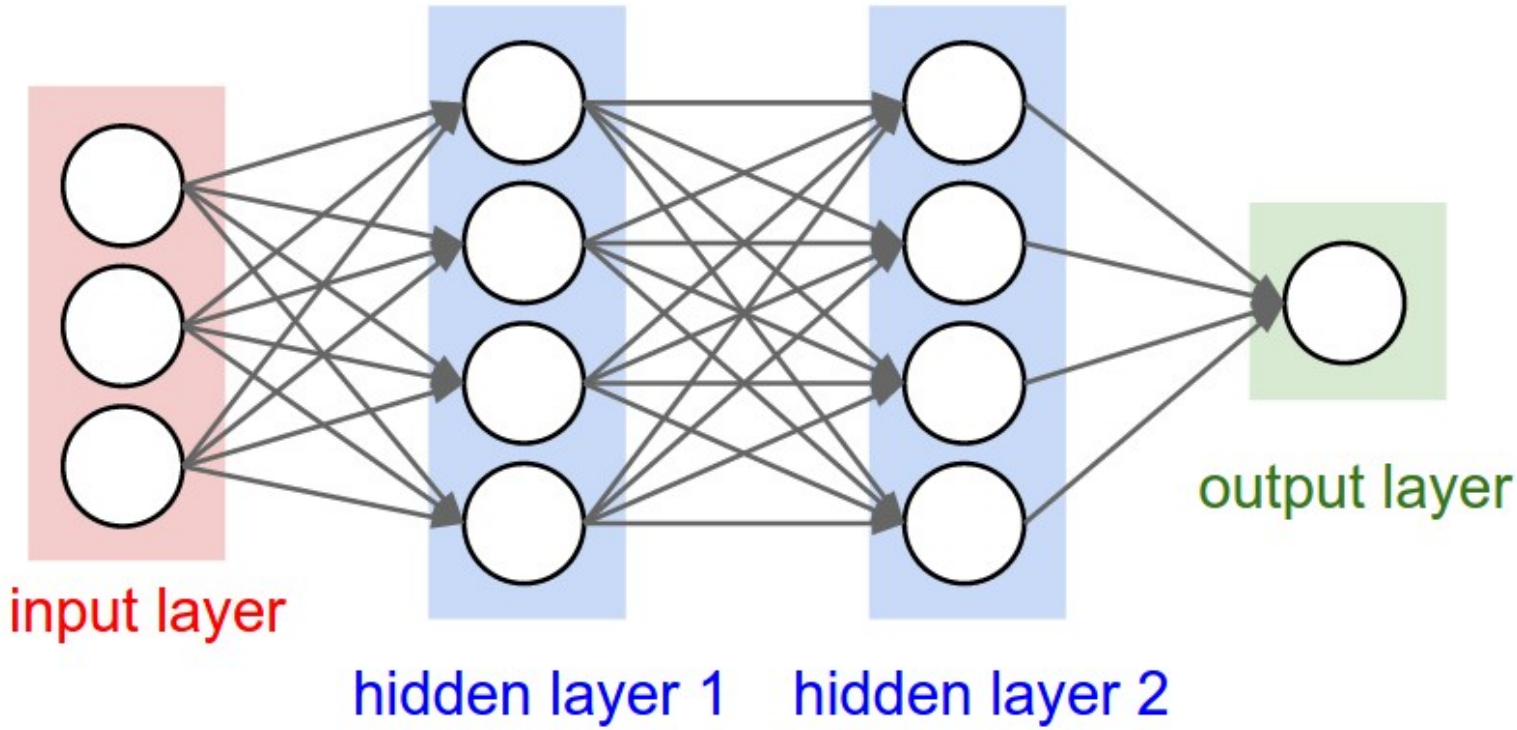

Una rete neurale a 3 livelli

Reti Neurali

Funzionamento

Il processo di apprendimento di una rete neurale è suddiviso in quattro fasi distinte

Reti Neurali

Funzionamento

Il processo di apprendimento di una rete neurale è suddiviso in quattro fasi distinte

- *Inizializzazione dei pesi*

Reti Neurali

Funzionamento

Il processo di apprendimento di una rete neurale è suddiviso in quattro fasi distinte

- *Inizializzazione dei pesi*
- *Forward Propagation*

Reti Neurali

Funzionamento

Il processo di apprendimento di una rete neurale è suddiviso in quattro fasi distinte

- *Inizializzazione dei pesi*
- *Forward Propagation*
- *Calcolo della Funzione di Perdita*

Reti Neurali

Funzionamento

Il processo di apprendimento di una rete neurale è suddiviso in quattro fasi distinte

- *Inizializzazione dei pesi*
- *Forward Propagation*
- *Calcolo della Funzione di Perdita*
- *Back Propagation*

Reti Neurali

Inizializzazione dei pesi

- Al momento della nascita gli esseri umani non sono in grado di discriminare nessun tipo di oggetto a causa del mancato addestramento della loro rete neurale biologica

Reti Neurali

Inizializzazione dei pesi

- Al momento della nascita gli esseri umani non sono in grado di discriminare nessun tipo di oggetto a causa del mancato addestramento della loro rete neurale biologica

- Per riprodurre questo comportamento, all'inizio della fase di training, i pesi sinaptici w_i di ciascun livello vengono inizializzati in maniera casuale

Reti Neurali

Forward Propagation

Definizione

La *Forward Propagation* è il meccanismo utilizzato da una rete neurale per associare ad un'immagine una determinata classe

Reti Neurali

Forward Propagation

Definizione

La *Forward Propagation* è il meccanismo utilizzato da una rete neurale per associare ad un'immagine una determinata classe

- L'output dei neuroni del livello i viene moltiplicato per la matrice dei pesi del livello $i + 1$ ottenendo il vettore v

Reti Neurali

Forward Propagation

Definizione

La *Forward Propagation* è il meccanismo utilizzato da una rete neurale per associare ad un'immagine una determinata classe

- L'output dei neuroni del livello i viene moltiplicato per la matrice dei pesi del livello $i + 1$ ottenendo il vettore v
- Al vettore v viene aggiunto il vettore dei bias del livello $i + 1$

Reti Neurali

Forward Propagation

Definizione

La *Forward Propagation* è il meccanismo utilizzato da una rete neurale per associare ad un'immagine una determinata classe

- L'output dei neuroni del livello i viene moltiplicato per la matrice dei pesi del livello $i+1$ ottenendo il vettore v
- Al vettore v viene aggiunto il vettore dei bias del livello $i+1$
- L'output del livello $i+1$ si ottiene applicando la funzione di attivazione f ad ogni entry del vettore v

Reti Neurali

Forward Propagation

Definizione

La *Forward Propagation* è il meccanismo utilizzato da una rete neurale per associare ad un'immagine una determinata classe

- L'output dei neuroni del livello i viene moltiplicato per la matrice dei pesi del livello $i+1$ ottenendo il vettore v
- Al vettore v viene aggiunto il vettore dei bias del livello $i+1$
- L'output del livello $i+1$ si ottiene applicando la funzione di attivazione f ad ogni entry del vettore v
- Le operazioni precedenti sono svolte per tutti i livelli ad eccezione dell'ultimo

Reti Neurali

Calcolo della funzione di perdita

Definizione

Una *funzione di perdita* L viene utilizzata per determinare l'errore di classificazione di una rete neurale

Reti Neurali

Calcolo della funzione di perdita

Definizione

Una *funzione di perdita* L viene utilizzata per determinare l'errore di classificazione di una rete neurale

- La funzione di perdita più usata è la *Mean Squared Error (MSE)* $L = \frac{1}{2}\sum(y - o)^2$

Reti Neurali

Calcolo della funzione di perdita

Definizione

Una *funzione di perdita* L viene utilizzata per determinare l'errore di classificazione di una rete neurale

- La funzione di perdita più usata è la *Mean Squared Error (MSE)* $L = \frac{1}{2}\sum(y - o)^2$
- y identifica l'etichetta dell'esempio considerato mentre o l'output della rete

Reti Neurali

Calcolo della funzione di perdita

Definizione

Una *funzione di perdita* L viene utilizzata per determinare l'errore di classificazione di una rete neurale

- La funzione di perdita più usata è la *Mean Squared Error (MSE)* $L = \frac{1}{2}\sum(y - o)^2$
- y identifica l'etichetta dell'esempio considerato mentre o l'output della rete
- Minimizzando la funzione di perdita L si riduce l'errore di una rete neurale

Reti Neurali

Calcolo della funzione di perdita

Definizione

Una *funzione di perdita* L viene utilizzata per determinare l'errore di classificazione di una rete neurale

- La funzione di perdita più usata è la *Mean Squared Error (MSE)* $L = \frac{1}{2}\sum(y - o)^2$
- y identifica l'etichetta dell'esempio considerato mentre o l'output della rete
- Minimizzando la funzione di perdita L si riduce l'errore di una rete neurale
- Calcolando la derivata di L in funzione dei pesi w_i si cerca di individuare il minimo globale della funzione di perdita

Reti Neurali

Funzione di perdita

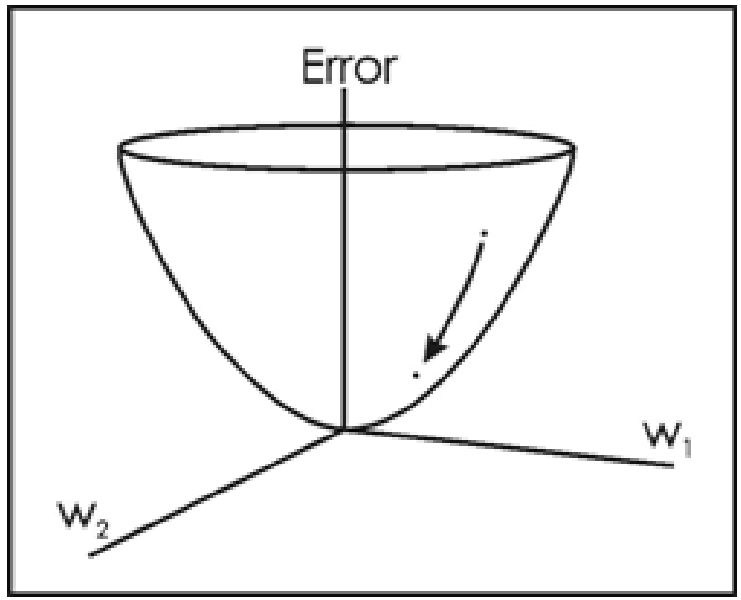

Mean Squared Error (MSE). I pesi w_1 e w_2 sono le variabili indipendenti. La funzione di perdita L è la variabile dipendente

Reti Neurali

Back Propagation

Definizione

La *Back Propagation* è il meccanismo utilizzato da una rete neurale per correggere gli errori di classificazione. Vengono individuati i pesi w_i che hanno influenzato maggiormente l'errore commesso e viene aggiornato il loro valore in modo da ridurre la funzione di perdita

Reti Neurali

Back Propagation

Definizione

La *Back Propagation* è il meccanismo utilizzato da una rete neurale per correggere gli errori di classificazione. Vengono individuati i pesi w_i che hanno influenzato maggiormente l'errore commesso e viene aggiornato il loro valore in modo da ridurre la funzione di perdita

- Per calcolare la derivata della funzione L in funzione dei pesi w_i viene usata la *regola della catena (chain rule)*

Reti Neurali

Back Propagation

Definizione

La *Back Propagation* è il meccanismo utilizzato da una rete neurale per correggere gli errori di classificazione. Vengono individuati i pesi w_i che hanno influenzato maggiormente l'errore commesso e viene aggiornato il loro valore in modo da ridurre la funzione di perdita

- Per calcolare la derivata della funzione L in funzione dei pesi w_i viene usata la *regola della catena (chain rule)*
- Questa regola è usata per trovare la derivata di una funzione composta

Reti Neurali

Aggiornamento dei Pesi e Learning Rate

- Il nuovo valore del peso w_i è dato dalla regola di aggiornamento $w_i = w_i - \eta \frac{\partial L}{\partial w_i} = w_i + \Delta w_i$ con $\eta > 0$

Reti Neurali

Aggiornamento dei Pesi e Learning Rate

- Il nuovo valore del peso w_i è dato dalla regola di aggiornamento $w_i = w_i - \eta \frac{\partial L}{\partial w_i} = w_i + \Delta w_i$ con $\eta > 0$
- Il *learning rate* η è un parametro usato per controllare la velocità di aggiornamento dei pesi

Reti Neurali

Aggiornamento dei Pesi e Learning Rate

- Il nuovo valore del peso w_i è dato dalla regola di aggiornamento $w_i = w_i - \eta \frac{\partial L}{\partial w_i} = w_i + \Delta w_i$ con $\eta > 0$
- Il *learning rate* η è un parametro usato per controllare la velocità di aggiornamento dei pesi
- Un learning rate alto comporta aggiornamenti rapidi, un tempo di esecuzione più basso, ma una maggiore probabilità di finire in un minimo locale

Reti Neurali

Aggiornamento dei Pesi e Learning Rate

- Il nuovo valore del peso w_i è dato dalla regola di aggiornamento $w_i = w_i - \eta \frac{\partial L}{\partial w_i} = w_i + \Delta w_i$ con $\eta > 0$
- Il *learning rate* η è un parametro usato per controllare la velocità di aggiornamento dei pesi
- Un learning rate alto comporta aggiornamenti rapidi, un tempo di esecuzione più basso, ma una maggiore probabilità di finire in un minimo locale
- Un learning rate basso diminuisce la probabilità di finire in un minimo locale, ma allunga notevolmente i tempi di esecuzione

Reti Neurali

Esempio Back Propagation

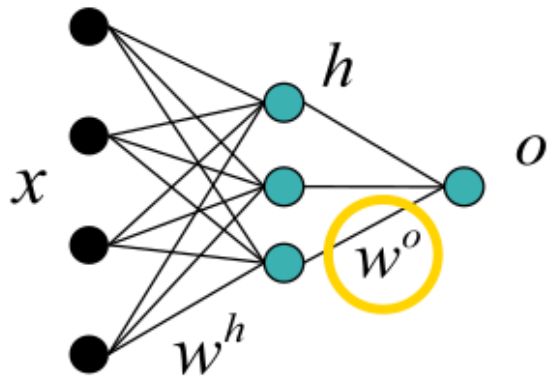

$$\boldsymbol{x} \in \mathbb{R}^{n,1} \quad \boldsymbol{w^h} \in \mathbb{R}^{n,m}$$

$$\boldsymbol{h} \in \mathbb{R}^{m,1} \quad \boldsymbol{w^o} \in \mathbb{R}^{1,m}$$

$$z_j^h = \sum_{i=0}^{n} w_{ij}^h x_i \qquad z^o = \sum_{j=0}^{m} w_j^o h_j$$

$$h_j = f(z_j^h) \qquad o = f(z^o)$$

Reti Neurali

Esempio Back Propagation

- Derivata di L in funzione del peso w_j^o

$$\frac{\partial L}{\partial w_j^o} = \frac{\partial L}{\partial o} \cdot \frac{\partial o}{\partial z^o} \cdot \frac{\partial z^o}{\partial w_j}$$

Reti Neurali

Esempio Back Propagation

- Derivata di L in funzione del peso w_j^o

$$\frac{\partial L}{\partial w_j^o} = \frac{\partial L}{\partial o} \cdot \frac{\partial o}{\partial z^o} \cdot \frac{\partial z^o}{\partial w_j}$$

  - $\frac{\partial L}{\partial o} = \frac{\partial}{\partial o}\left[\frac{1}{2}(y-o)^2\right] = -(y-o)$

Reti Neurali

Esempio Back Propagation

- Derivata di L in funzione del peso w_j^o

$$\frac{\partial L}{\partial w_j^o} = \frac{\partial L}{\partial o} \cdot \frac{\partial o}{\partial z^o} \cdot \frac{\partial z^o}{\partial w_j}$$

  - $\frac{\partial L}{\partial o} = \frac{\partial}{\partial o}\left[\frac{1}{2}(y-o)^2\right] = -(y-o)$
  - $\frac{\partial o}{\partial z^o} = f'(z^o)$

Reti Neurali

Esempio Back Propagation

- Derivata di L in funzione del peso w_j^o

$$\frac{\partial L}{\partial w_j^o} = \frac{\partial L}{\partial o} \cdot \frac{\partial o}{\partial z^o} \cdot \frac{\partial z^o}{\partial w_j}$$

  - $\frac{\partial L}{\partial o} = \frac{\partial}{\partial o}\left[\frac{1}{2}(y-o)^2\right] = -(y-o)$
  - $\frac{\partial o}{\partial z^o} = f'(z^o)$
  - $\frac{\partial z^o}{\partial w_j^o} = h_j$

Reti Neurali

Esempio Back Propagation

- Risultato della derivata di L in funzione del peso w_j^o

$$\frac{\partial L}{\partial w_j^o} = -(y - o) \cdot f'(z^o) \cdot h_j = -\delta_j^o h_j$$

Reti Neurali

Esempio Back Propagation

- Risultato della derivata di L in funzione del peso w_j^o

$$\frac{\partial L}{\partial w_j^o} = -(y - o) \cdot f'(z^o) \cdot h_j = -\delta_j^o h_j$$

- Aggiornamento del peso w_j^o

$$\Delta w_j^o = \eta \delta_j^o h_j$$

Reti Neurali

Esempio Back Propagation

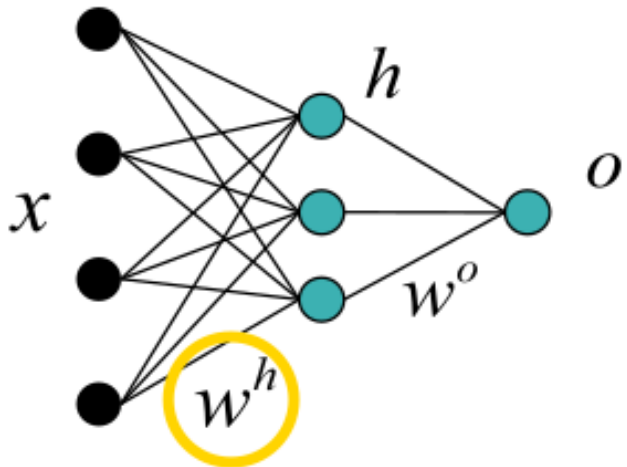

$$\frac{\partial L}{\partial w_{ij}^h} = \frac{\partial L}{\partial o} \cdot \frac{\partial o}{\partial z^o} \cdot \frac{\partial z^o}{\partial h_j} \cdot \frac{\partial h_j}{\partial z_j^h} \cdot \frac{\partial z_j^h}{\partial w_{ij}^h}$$

Reti Neurali

Esempio Back Propagation

$$\frac{\partial L}{\partial o} = \frac{\partial}{\partial o}\left[\frac{1}{2}(y-o)^2\right] = -(y-o)$$

Reti Neurali

Esempio Back Propagation

$$\frac{\partial L}{\partial o} = \frac{\partial}{\partial o}\left[\frac{1}{2}(y-o)^2\right] = -(y-o)$$

$$\frac{\partial o}{\partial z^o} = f'(z^o)$$

Reti Neurali

Esempio Back Propagation

$$\frac{\partial L}{\partial o} = \frac{\partial}{\partial o}\left[\frac{1}{2}(y-o)^2\right] = -(y-o)$$

$$\frac{\partial o}{\partial z^o} = f'(z^o)$$

$$\frac{\partial z^o}{\partial h_j} = w_j^o$$

Reti Neurali

Esempio Back Propagation

$$\frac{\partial L}{\partial o} = \frac{\partial}{\partial o}\left[\frac{1}{2}(y-o)^2\right] = -(y-o)$$

$$\frac{\partial o}{\partial z^o} = f'(z^o)$$

$$\frac{\partial z^o}{\partial h_j} = w_j^o$$

$$\frac{\partial h_j}{\partial z_j^h} = f'(z_j^h)$$

Reti Neurali

Esempio Back Propagation

$$\frac{\partial L}{\partial o} = \frac{\partial}{\partial o}\left[\frac{1}{2}(y-o)^2\right] = -(y-o)$$

$$\frac{\partial o}{\partial z^o} = f'(z^o)$$

$$\frac{\partial z^o}{\partial h_j} = w_j^o$$

$$\frac{\partial h_j}{\partial z_j^h} = f'(z_j^h)$$

$$\frac{\partial z_j^h}{\partial w_{ij}^h} = x_i$$

Reti Neurali

Esempio Back Propagation

- Risultato della derivata di L in funzione del peso w_{ij}^h

$$\frac{\partial L}{\partial w_{ij}^h} = -(y - o) \cdot f'(z^o) \cdot w_j^o \cdot f'(z_j^h) \cdot x_i = -\delta_j^h x_i$$

Reti Neurali

Esempio Back Propagation

- Risultato della derivata di L in funzione del peso w_{ij}^h

$$\frac{\partial L}{\partial w_{ij}^h} = -(y - o) \cdot f'(z^o) \cdot w_j^o \cdot f'(z_j^h) \cdot x_i = -\delta_j^h x_i$$

- Aggiornamento del peso w_{ij}^h

$$\Delta w_{ij}^h = \eta \delta_j^h x_i$$

Reti Neurali

Rete Neurale Convoluzionale

Definizione

Una *Rete Neurale Convoluzionale* è una variante di una rete neurale classica. Permette la condivisione dei pesi sinaptici tra i neuroni di un livello e consente di discriminare le varie feature che compongono un'immagine

Reti Neurali

Rete Neurale Convoluzionale

Definizione

Una *Rete Neurale Convoluzionale* è una variante di una rete neurale classica. Permette la condivisione dei pesi sinaptici tra i neuroni di un livello e consente di discriminare le varie feature che compongono un'immagine

- Viene definito un nuovo tipo di livello: il *Livello Convoluzionale*

Reti Neurali

Rete Neurale Convoluzionale

Definizione

Una *Rete Neurale Convoluzionale* è una variante di una rete neurale classica. Permette la condivisione dei pesi sinaptici tra i neuroni di un livello e consente di discriminare le varie feature che compongono un'immagine

- Viene definito un nuovo tipo di livello: il *Livello Convoluzionale*
- Un livello convoluzionale è formato da diversi *filtri*

Reti Neurali

Rete Neurale Convoluzionale

Definizione

Una *Rete Neurale Convoluzionale* è una variante di una rete neurale classica. Permette la condivisione dei pesi sinaptici tra i neuroni di un livello e consente di discriminare le varie feature che compongono un'immagine

- Viene definito un nuovo tipo di livello: il *Livello Convoluzionale*
- Un livello convoluzionale è formato da diversi *filtri*
- La *profondità (depth)* di un livello convoluzionale è data dal numero di filtri che lo compongono

Reti Neurali

Filtri e Livelli Convoluzionali

- I filtri sono le matrici contenenti i pesi sinaptici del livello convoluzionale

Reti Neurali

Filtri e Livelli Convoluzionali

- I filtri sono le matrici contenenti i pesi sinaptici del livello convoluzionale
- Ogni filtro ricerca all'interno delle immagini della rete una o più *feature*: linee, curve, pattern

Reti Neurali

Filtri e Livelli Convoluzionali

- I filtri sono le matrici contenenti i pesi sinaptici del livello convoluzionale
- Ogni filtro ricerca all'interno delle immagini della rete una o più *feature*: linee, curve, pattern
- Per apprendere nel miglior modo possibile il contenuto semantico di un'immagine, la rete deve saper ricercare feature sempre più complesse

Reti Neurali

Filtri e Livelli Convoluzionali

- I filtri sono le matrici contenenti i pesi sinaptici del livello convoluzionale
- Ogni filtro ricerca all'interno delle immagini della rete una o più *feature*: linee, curve, pattern
- Per apprendere nel miglior modo possibile il contenuto semantico di un'immagine, la rete deve saper ricercare feature sempre più complesse
- Mettendo in sequenza più livelli convoluzionali si possono ottenere feature complesse

Reti Neurali

Filtri e Livelli Convoluzionali

- I filtri sono le matrici contenenti i pesi sinaptici del livello convoluzionale
- Ogni filtro ricerca all'interno delle immagini della rete una o più *feature*: linee, curve, pattern
- Per apprendere nel miglior modo possibile il contenuto semantico di un'immagine, la rete deve saper ricercare feature sempre più complesse
- Mettendo in sequenza più livelli convoluzionali si possono ottenere feature complesse
- L'output di un generico livello convoluzionale i diventa l'input del successivo livello $i + 1$. Le feature prodotte da i sono meno complesse di quelle ottenute da $i + 1$

Reti Neurali

Funzionamento

- I pesi dei filtri di un livello convoluzionale sono inizializzati in maniera casuale

Reti Neurali

Funzionamento

- I pesi dei filtri di un livello convoluzionale sono inizializzati in maniera casuale

- Vengono utilizzate le stesse funzioni di attivazione e le stesse funzioni di perdita dei livelli fully-connected

Reti Neurali

Funzionamento

- I pesi dei filtri di un livello convoluzionale sono inizializzati in maniera casuale
- Vengono utilizzate le stesse funzioni di attivazione e le stesse funzioni di perdita dei livelli fully-connected
- La forward e la back propagation sono le uniche fasi definite diversamente

Reti Neurali

Forward Propagation

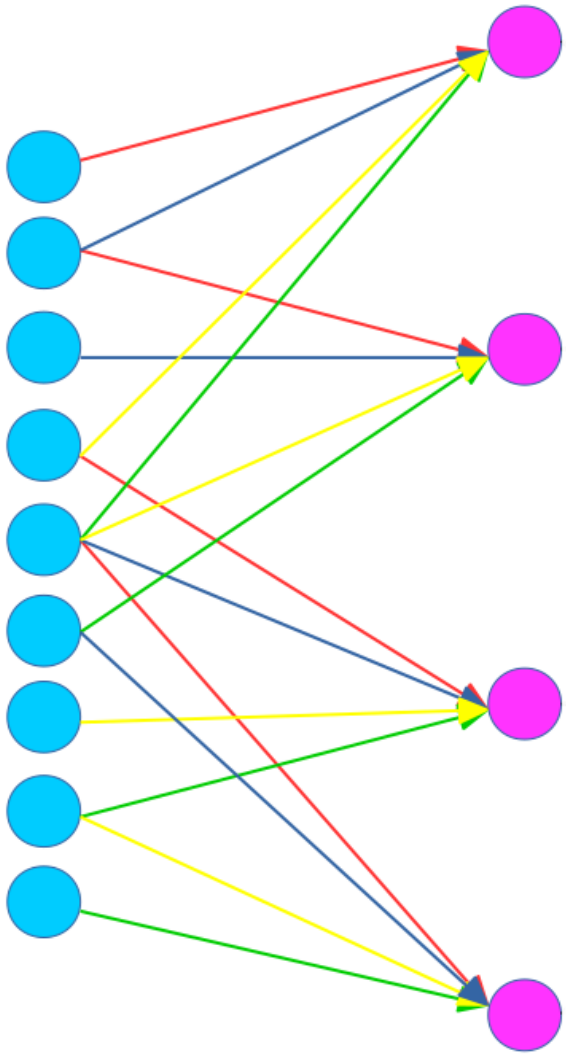

Reti Neurali

Forward Propagation

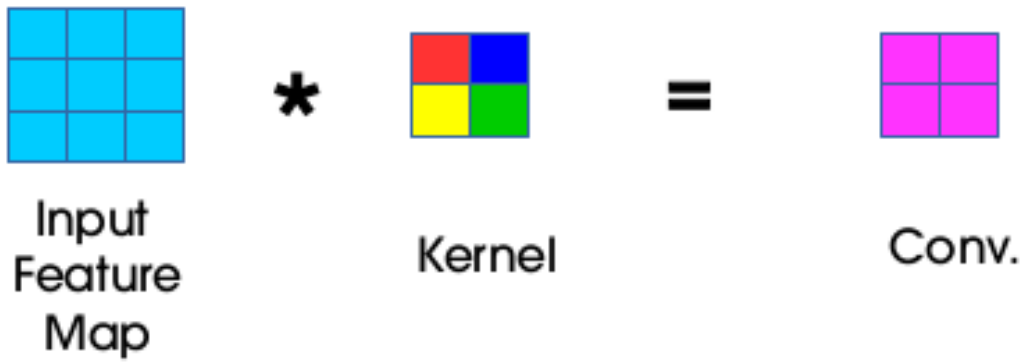

- Le matrici di input e di output di un livello convoluzionale prendono il nome di *feature map*

Reti Neurali

Forward Propagation

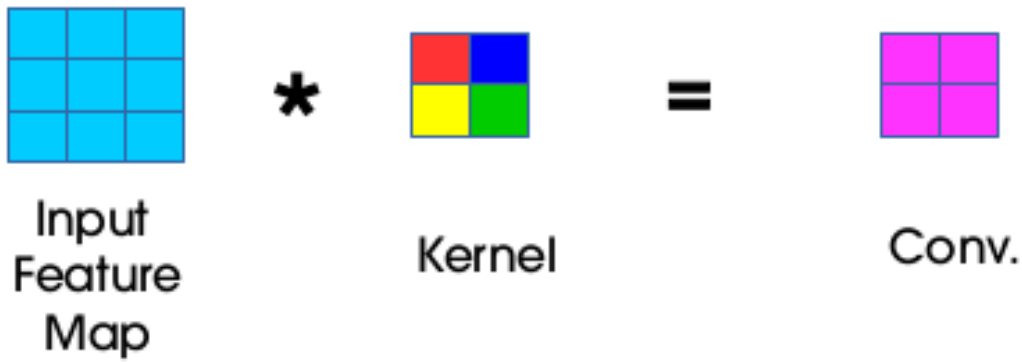

- Le matrici di input e di output di un livello convoluzionale prendono il nome di *feature map*
- I filtri sono meglio conosciuti con il nome di *kernel*

Reti Neurali

Forward Propagation

- All'inizio della forward propagation, il kernel viene sovrapposto alla parte superiore sinistra della feature map di input

Reti Neurali

Forward Propagation

- All'inizio della forward propagation, il kernel viene sovrapposto alla parte superiore sinistra della feature map di input
- Viene eseguita la *convoluzione* tra le due sottomatrici ed il risultato ottenuto viene salvato nella feature map di output

Reti Neurali

Forward Propagation

- All'inizio della forward propagation, il kernel viene sovrapposto alla parte superiore sinistra della feature map di input
- Viene eseguita la *convoluzione* tra le due sottomatrici ed il risultato ottenuto viene salvato nella feature map di output
- Il kernel viene spostato di una posizione verso destra e viene rieseguita nuovamente la convoluzione

Reti Neurali

Forward Propagation

- All'inizio della forward propagation, il kernel viene sovrapposto alla parte superiore sinistra della feature map di input
- Viene eseguita la *convoluzione* tra le due sottomatrici ed il risultato ottenuto viene salvato nella feature map di output
- Il kernel viene spostato di una posizione verso destra e viene rieseguita nuovamente la convoluzione
- Terminata la riga, il kernel viene posizionato nuovamente nella parte sinistra della feature map di input, ma una riga più in basso

Reti Neurali

Forward Propagation

- All'inizio della forward propagation, il kernel viene sovrapposto alla parte superiore sinistra della feature map di input
- Viene eseguita la *convoluzione* tra le due sottomatrici ed il risultato ottenuto viene salvato nella feature map di output
- Il kernel viene spostato di una posizione verso destra e viene rieseguita nuovamente la convoluzione
- Terminata la riga, il kernel viene posizionato nuovamente nella parte sinistra della feature map di input, ma una riga più in basso
- Gli ultimi due passaggi vengono ripetuti fino a quando non è stata riempita completamente tutta la feature map di output

Reti Neurali

Forward Propagation

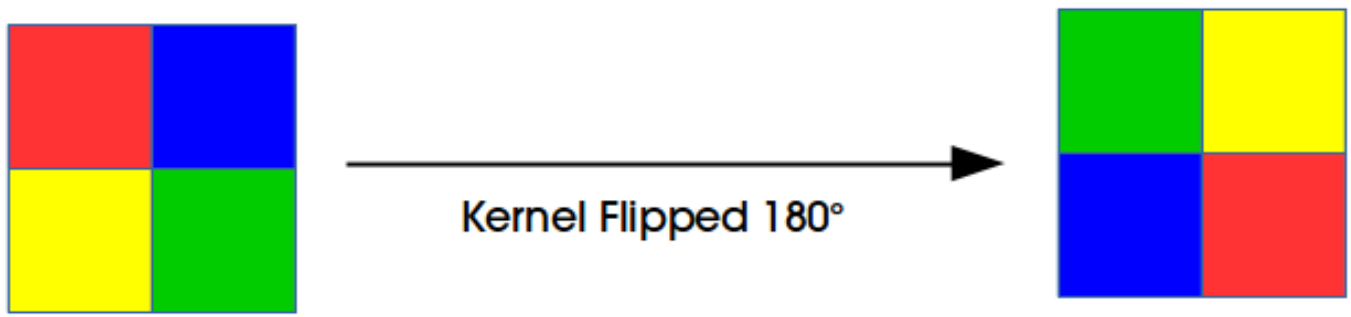

Il kernel viene ruotato di 180° *per poter eseguire la convoluzione*

Reti Neurali

Forward Propagation

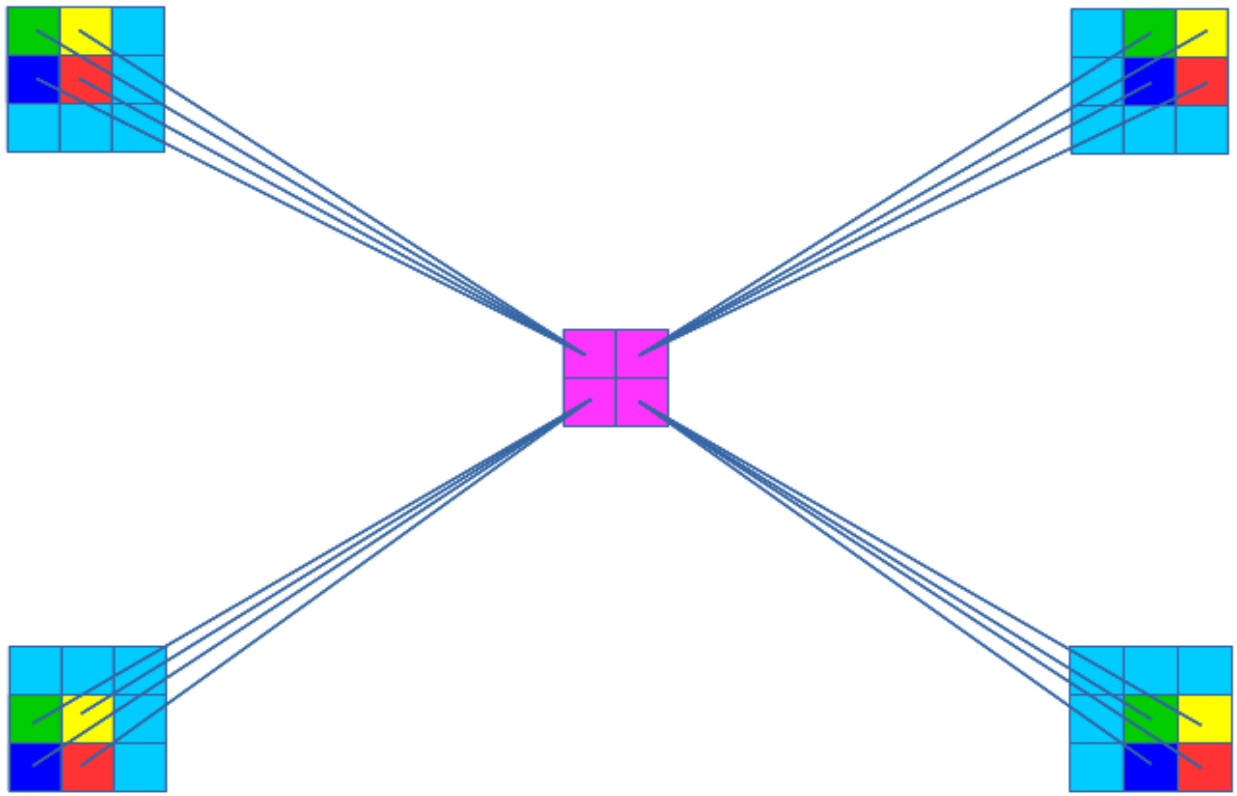

Forward Propagation di un livello convoluzionale

Reti Neurali

Considerazioni Forward Propagation

- Al termine della forward propagation, la funzione di attivazione f viene applicata ad ogni elemento della feature map di output

Reti Neurali

Considerazioni Forward Propagation

- Al termine della forward propagation, la funzione di attivazione f viene applicata ad ogni elemento della feature map di output

- Un kernel è una matrice quadrata di dimensione $K \times K$

Reti Neurali

Considerazioni Forward Propagation

- Al termine della forward propagation, la funzione di attivazione f viene applicata ad ogni elemento della feature map di output
- Un kernel è una matrice quadrata di dimensione $K \times K$
- La feature map di input ha dimensione $W \times H$ con $W = H$

Reti Neurali

Considerazioni Forward Propagation

- Al termine della forward propagation, la funzione di attivazione f viene applicata ad ogni elemento della feature map di output
- Un kernel è una matrice quadrata di dimensione $K \times K$
- La feature map di input ha dimensione $W \times H$ con $W = H$
- La feature map di output è una matrice quadrata di dimensione $O \times O$ con $O = (W - K) + 1$

Reti Neurali

Back Propagation

Definizione

La Back Propagation di una rete neurale convoluzionale ha come obiettivo l'aggiornamento dei pesi contenuti nei kernel di un livello. Per ciascuno dei pesi di un kernel viene calcolata la derivata parziale $\frac{\partial L}{\partial w^l_{m',n'}}$ che rappresenta l'influenza del peso $w^l_{m',n'}$ sulla funzione di perdita L

Reti Neurali

Back Propagation

Definizione

La Back Propagation di una rete neurale convoluzionale ha come obiettivo l'aggiornamento dei pesi contenuti nei kernel di un livello. Per ciascuno dei pesi di un kernel viene calcolata la derivata parziale $\frac{\partial L}{\partial w^l_{m',n'}}$ che rappresenta l'influenza del peso $w^l_{m',n'}$ sulla funzione di perdita L

- La Back Propagation viene suddivisa in due fasi distinte

Reti Neurali

Back Propagation

Definizione

La Back Propagation di una rete neurale convoluzionale ha come obiettivo l'aggiornamento dei pesi contenuti nei kernel di un livello. Per ciascuno dei pesi di un kernel viene calcolata la derivata parziale $\frac{\partial L}{\partial w^l_{m',n'}}$ che rappresenta l'influenza del peso $w^l_{m',n'}$ sulla funzione di perdita L

- La Back Propagation viene suddivisa in due fasi distinte
  - Il calcolo della matrice degli errori δ

Reti Neurali

Back Propagation

Definizione

La Back Propagation di una rete neurale convoluzionale ha come obiettivo l'aggiornamento dei pesi contenuti nei kernel di un livello. Per ciascuno dei pesi di un kernel viene calcolata la derivata parziale $\frac{\partial L}{\partial w^l_{m',n'}}$ che rappresenta l'influenza del peso $w^l_{m',n'}$ sulla funzione di perdita L

- La Back Propagation viene suddivisa in due fasi distinte
  - Il calcolo della matrice degli errori δ
  - L'aggiornamento dei pesi del kernel

Reti Neurali

Calcolo matrice dei δ

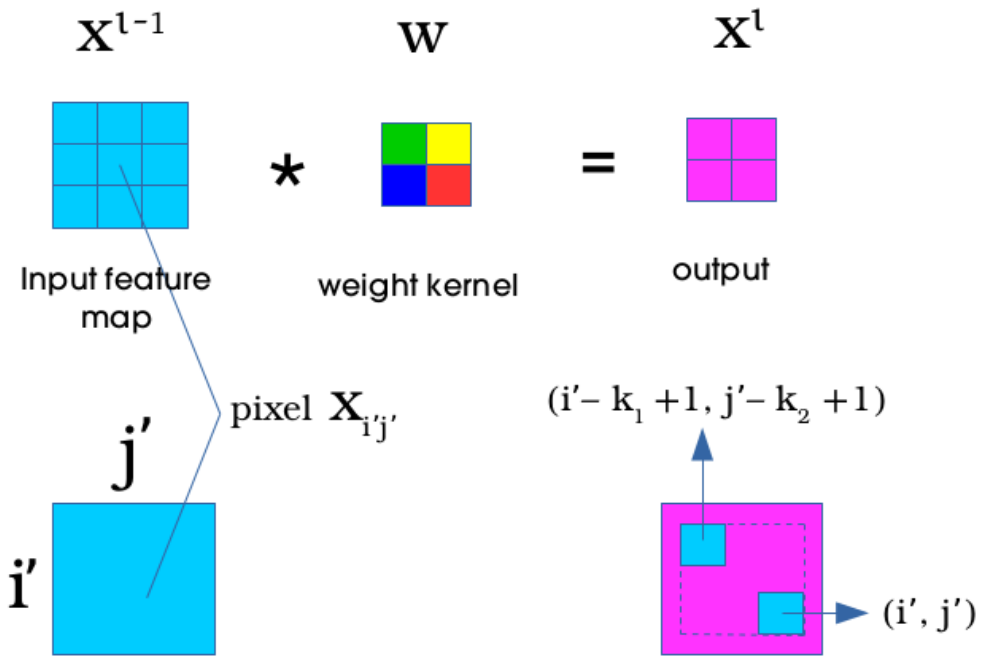

Le linee tratteggiate presenti nella feature map di output individuano la regione dei pixel influenzati dal pixel $x_{i',j'}$. k_1 e k_2 definiscono la grandezza della regione considerata

Reti Neurali

Calcolo matrice dei δ

- L'influenza del pixel $x_{i',j'}$ sulla funzione di perdita L è data da

$$\delta^l_{i',j'} = \frac{\partial L}{\partial x^l_{i',j'}}$$

Reti Neurali

Calcolo matrice dei δ

- L'influenza del pixel $x_{i',j'}$ sulla funzione di perdita L è data da

$$\delta^l_{i',j'} = \frac{\partial L}{\partial x^l_{i',j'}}$$

- Applicando la regola della catena si ottiene

$$\frac{\partial L}{\partial x^l_{i',j'}} = \sum_{m=0}^{k_1-1} \sum_{n=0}^{k_2-1} \frac{\partial L}{\partial x^{l+1}_{i'-m,j'-n}} \frac{\partial x^{l+1}_{i'-m,j'-n}}{\partial x^l_{i',j'}}$$

$$= \sum_{m=0}^{k_1-1} \sum_{n=0}^{k_2-1} \delta^{l+1}_{i'-m,j'-n} \frac{\partial x^{l+1}_{i'-m,j'-n}}{\partial x^l_{i',j'}}$$

Reti Neurali

Calcolo matrice dei δ

$$\frac{\partial L}{\partial x^l_{i',j'}} = \sum_{m=0}^{k_1-1} \sum_{n=0}^{k_2-1} \delta^{l+1}_{i'-m,j'-n} w^{l+1}_{m,n} f'\left(x^l_{i',j'}\right)$$

$$= \text{rot}_{180^\circ} \left\{ \sum_{m=0}^{k_1-1} \sum_{n=0}^{k_2-1} \delta^{l+1}_{i'+m,j'+n} w^{l+1}_{m,n} \right\} f'\left(x^l_{i',j'}\right)$$

$$= \delta^{l+1}_{i',j'} * \text{rot}_{180^\circ} \left\{ w^{l+1}_{m,n} \right\} f'\left(x^l_{i',j'}\right)$$

Reti Neurali

Aggiornamento dei pesi

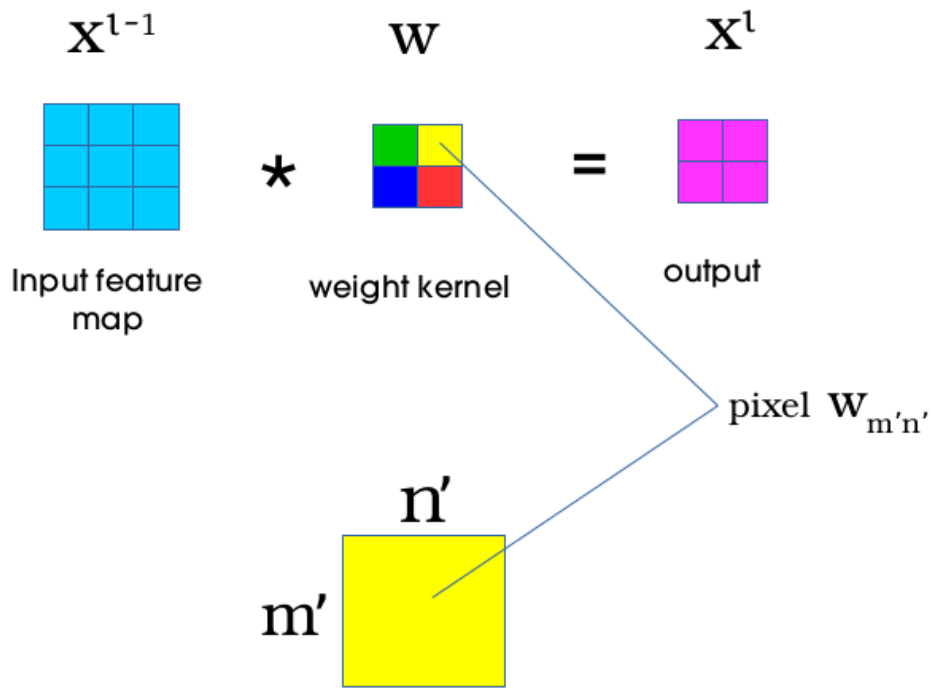

Durante la fase di forward propagation, il peso $w_{m',n'}$ ha contribuito a calcolare tutti i valori che costituiscono la feature map di output

Reti Neurali

Aggiornamento dei pesi

- Il calcolo di $\frac{\partial L}{\partial w^l_{m',n'}}$ usando la regola della catena è dato da

$$\frac{\partial L}{\partial w^l_{m',n'}} = \sum_{i=0}^{W-K} \sum_{j=0}^{W-K} \frac{\partial L}{\partial x^l_{i,j}} \frac{\partial x^l_{i,j}}{\partial w^l_{m',n'}}$$

$$= \sum_{i=0}^{W-K} \sum_{j=0}^{W-K} \delta^l_{i,j} \cdot o^{l-1}_{i+m',j+n'}$$

$$= rot_{180^\circ}\{\delta^l_{i,j}\} * o^{l-1}_{m',n'}$$

Reti Neurali

Aggiornamento dei pesi

- Il calcolo di $\frac{\partial L}{\partial w^l_{m',n'}}$ usando la regola della catena è dato da

$$\frac{\partial L}{\partial w^l_{m',n'}} = \sum_{i=0}^{W-K} \sum_{j=0}^{W-K} \frac{\partial L}{\partial x^l_{i,j}} \frac{\partial x^l_{i,j}}{\partial w^l_{m',n'}}$$

$$= \sum_{i=0}^{W-K} \sum_{j=0}^{W-K} \delta^l_{i,j} \cdot o^{l-1}_{i+m',j+n'}$$

$$= rot_{180^\circ}\{\delta^l_{i,j}\} * o^{l-1}_{m',n'}$$

- $x^l_{i,j} = \sum_m \sum_n w^l_{m,n} o^{l-1}_{i+m,j+n} + b^l$

Reti Neurali

Aggiornamento dei pesi

- Il calcolo di $\frac{\partial L}{\partial w^l_{m',n'}}$ usando la regola della catena è dato da

$$\frac{\partial L}{\partial w^l_{m',n'}} = \sum_{i=0}^{W-K} \sum_{j=0}^{W-K} \frac{\partial L}{\partial x^l_{i,j}} \frac{\partial x^l_{i,j}}{\partial w^l_{m',n'}}$$

$$= \sum_{i=0}^{W-K} \sum_{j=0}^{W-K} \delta^l_{i,j} \cdot o^{l-1}_{i+m',j+n'}$$

$$= rot_{180^\circ}\{\delta^l_{i,j}\} * o^{l-1}_{m',n'}$$

- $x^l_{i,j} = \sum_m \sum_n w^l_{m,n} o^{l-1}_{i+m,j+n} + b^l$
- $o^{l-1}_{m',n'} = f(x^{l-1}_{i',j'})$

Reti Neurali

Aggiornamento dei pesi

- Il risultato della convoluzione tra $\delta^l_{i,j}$ e $o^{l-1}_{m',n'}$ individua il nuovo valore del peso $w^l_{m',n'}$

Reti Neurali

Aggiornamento dei pesi

- Il risultato della convoluzione tra $\delta^l_{i,j}$ e $o^{l-1}_{m',n'}$ individua il nuovo valore del peso $w^l_{m',n'}$

- La convoluzione è svolta per ciascuno dei pesi che costituiscono un kernel

Reti Neurali

Back Propagation

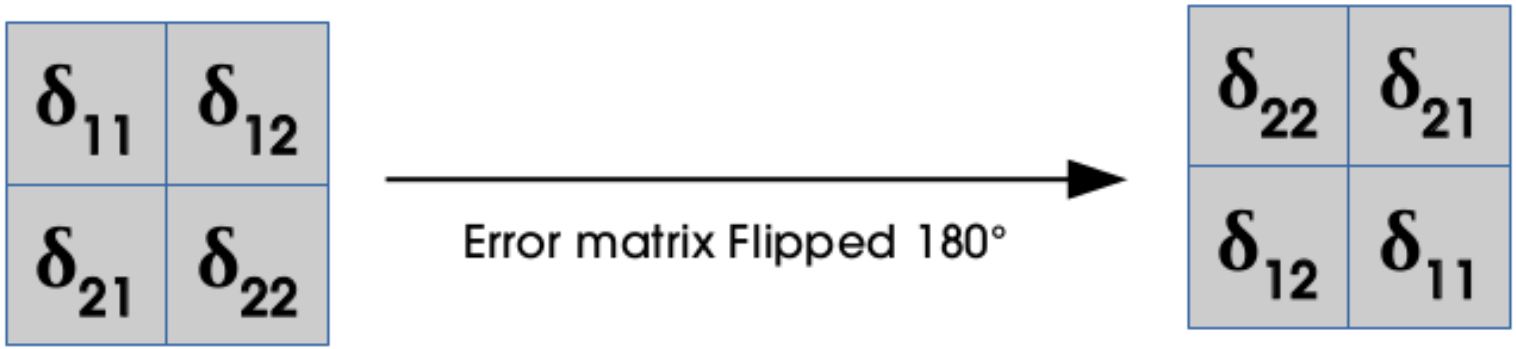

La matrice degli errori δ deve essere ruotata di 180° per poter eseguire la convoluzione

Reti Neurali

Esempio Back Propagation

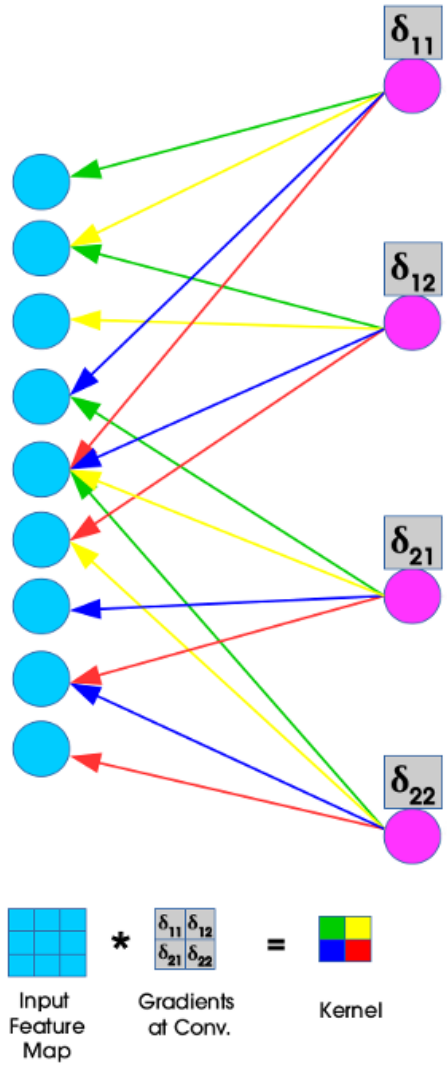

Reti Neurali

Esempio Back Propagation

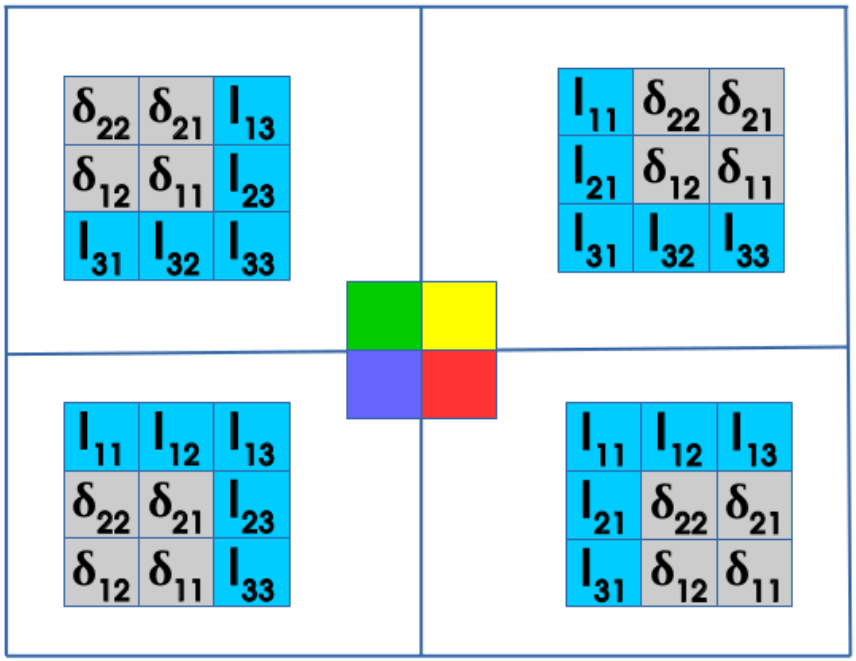

Il kernel aggiornato viene ricavato dalla convoluzione tra la matrice degli errori δ e la feature map di input

Implementazione della Rete

Implementazione della Rete

Obiettivo

- Sfruttando l'architettura per il calcolo parallelo *CUDA*, si vuole costruire una rete neurale convoluzionale che permetta di riconoscere cifre numeriche scritte a mano

Implementazione della Rete

Obiettivo

- Sfruttando l'architettura per il calcolo parallelo *CUDA*, si vuole costruire una rete neurale convoluzionale che permetta di riconoscere cifre numeriche scritte a mano

- Le cifre da riconoscere sono salvate come immagini in scala di grigio a 8 bit. Un pixel può assumere solo valori compresi nell'intervallo $[0, 255]$

Implementazione della Rete

Obiettivo

- Sfruttando l'architettura per il calcolo parallelo *CUDA*, si vuole costruire una rete neurale convoluzionale che permetta di riconoscere cifre numeriche scritte a mano

- Le cifre da riconoscere sono salvate come immagini in scala di grigio a 8 bit. Un pixel può assumere solo valori compresi nell'intervallo $[0, 255]$

- L'output della rete è dato dalle 10 cifre numeriche che si vogliono riconoscere

Implementazione della Rete

Obiettivo

- Sfruttando l'architettura per il calcolo parallelo *CUDA*, si vuole costruire una rete neurale convoluzionale che permetta di riconoscere cifre numeriche scritte a mano

- Le cifre da riconoscere sono salvate come immagini in scala di grigio a 8 bit. Un pixel può assumere solo valori compresi nell'intervallo $[0, 255]$

- L'output della rete è dato dalle 10 cifre numeriche che si vogliono riconoscere

- La rete riceve in input un'immagine e le associa la cifra numerica corrispondente

Implementazione della Rete

Dati

- La dimensione delle immagini che costituiscono gli esempi del training e del test set hanno una dimensione di 28×28

Implementazione della Rete

Dati

- La dimensione delle immagini che costituiscono gli esempi del training e del test set hanno una dimensione di 28×28

- Le etichette sono rappresentate da numeri interi positivi

Implementazione della Rete

Dati

- La dimensione delle immagini che costituiscono gli esempi del training e del test set hanno una dimensione di 28×28
- Le etichette sono rappresentate da numeri interi positivi
- Il training ed il test set provengono dal database *MNIST* e contengono rispettativamente 60000 esempi di train e 10000 di test

Implementazione della Rete

Rete CUDA

- Per potere sfruttare le potenzialità del paradigma ad oggetti, il codice host della rete CUDA è scritto in C++

Implementazione della Rete

Rete CUDA

- Per potere sfruttare le potenzialità del paradigma ad oggetti, il codice host della rete CUDA è scritto in C++
- I livelli implementati devono rispettare un'interfaccia comune e vengono modellati come classi

Implementazione della Rete

Rete CUDA

- Per potere sfruttare le potenzialità del paradigma ad oggetti, il codice host della rete CUDA è scritto in C++
- I livelli implementati devono rispettare un'interfaccia comune e vengono modellati come classi
- Le funzioni abibite alla fase di train, di test e al calcolo dell'accuratezza sono contenute in unica classe chiamata *Network*

Implementazione della Rete

Rete CUDA

- Quando viene definito un livello, l'utente non deve inserire anche la dimensione di output del livello precedente, ma solo quella del livello che sta definendo

Implementazione della Rete

Rete CUDA

- Quando viene definito un livello, l'utente non deve inserire anche la dimensione di output del livello precedente, ma solo quella del livello che sta definendo
- I pesi iniziali della rete possono essere generati in maniera casuale

Implementazione della Rete

Rete CUDA

- Quando viene definito un livello, l'utente non deve inserire anche la dimensione di output del livello precedente, ma solo quella del livello che sta definendo
- I pesi iniziali della rete possono essere generati in maniera casuale
- Per migliorare l'accuratezza della rete, viene utilizzato il meccanismo delle *epoche* che consiste nel ripetere più volte la forward e la back propagation sulla stessa immagine

Implementazione della Rete

Rete CUDA

- Quando viene definito un livello, l'utente non deve inserire anche la dimensione di output del livello precedente, ma solo quella del livello che sta definendo
- I pesi iniziali della rete possono essere generati in maniera casuale
- Per migliorare l'accuratezza della rete, viene utilizzato il meccanismo delle *epoche* che consiste nel ripetere più volte la forward e la back propagation sulla stessa immagine
- Le funzioni di attivazione implementate dalla rete sono la *Sigmoide*, la *Tangente Iperbolica* e la *SoftPlus*

Implementazione della Rete

Caratteristiche tecniche

- Per implementare i livelli della rete sono stati usati gli *unique pointer* perché permettono all'utente di non deve specificare il numero di livelli che vuole usare e non deve preoccuparsi di deallocarli al termine dell'esecuzione

Implementazione della Rete

Caratteristiche tecniche

- Per implementare i livelli della rete sono stati usati gli *unique pointer* perché permettono all'utente di non deve specificare il numero di livelli che vuole usare e non deve preoccuparsi di deallocarli al termine dell'esecuzione
- All'inizio della fase di train, l'intero training set viene caricato nella GRAM utilizzando il meccanismo della *pinned memory*

Implementazione della Rete

Caratteristiche tecniche

- Per implementare i livelli della rete sono stati usati gli *unique pointer* perché permettono all'utente di non deve specificare il numero di livelli che vuole usare e non deve preoccuparsi di deallocarli al termine dell'esecuzione
- All'inizio della fase di train, l'intero training set viene caricato nella GRAM utilizzando il meccanismo della *pinned memory*
- Prima della fase di test, il training set viene deallocato e al suo posto viene caricato il test set sempre con il meccanismo *pinned memory*

Implementazione della Rete

Caratteristiche tecniche

- Per implementare i livelli della rete sono stati usati gli *unique pointer* perché permettono all'utente di non deve specificare il numero di livelli che vuole usare e non deve preoccuparsi di deallocarli al termine dell'esecuzione
- All'inizio della fase di train, l'intero training set viene caricato nella GRAM utilizzando il meccanismo della *pinned memory*
- Prima della fase di test, il training set viene deallocato e al suo posto viene caricato il test set sempre con il meccanismo *pinned memory*
- Le strutture dati usate dai singoli livelli vengono deallocate automaticamente al termine dell'esecuzione del processo

Implementazione della Rete

Librerie

- Per eseguire le varie operazioni algebriche è stata utilizzata la libreria CUDA chiamata *cuBLAS*

Implementazione della Rete

Librerie

- Per eseguire le varie operazioni algebriche è stata utilizzata la libreria CUDA chiamata *cuBLAS*
- Durante la costruzione della rete, più di preciso quando si eseguivano i test intermedi, si è osservato che la funzione adibita al calcolo del prodotto tra matrici *cublasGemm* risulta più lenta di *cublasGemv* che effettua il prodotto tra matrici e vettori

Implementazione della Rete

Librerie

- Per eseguire le varie operazioni algebriche è stata utilizzata la libreria CUDA chiamata *cuBLAS*
- Durante la costruzione della rete, più di preciso quando si eseguivano i test intermedi, si è osservato che la funzione adibita al calcolo del prodotto tra matrici *cublasGemm* risulta più lenta di *cublasGemv* che effettua il prodotto tra matrici e vettori
- A fronte di questi risultati, si è scelto di usare la funzione *cublasGemv* per eseguire i prodotti matrice-vettore

Implementazione della Rete

Librerie

- Per eseguire le varie operazioni algebriche è stata utilizzata la libreria CUDA chiamata *cuBLAS*
- Durante la costruzione della rete, più di preciso quando si eseguivano i test intermedi, si è osservato che la funzione adibita al calcolo del prodotto tra matrici *cublasGemm* risulta più lenta di *cublasGemv* che effettua il prodotto tra matrici e vettori
- A fronte di questi risultati, si è scelto di usare la funzione *cublasGemv* per eseguire i prodotti matrice-vettore
- I pesi iniziali della rete vengono generati in maniera casuale utilizzando l'algoritmo *xorWow* contenuto nella libreria di CUDA *cuRand*

Implementazione della Rete

Stream

- Se la funzione *cublasGemm* viene utilizzata insieme agli *streams*, il tempo di calcolo per eseguire i prodotti tra matrici dovrebbe ridursi notevolmente

Implementazione della Rete

Stream

- Se la funzione *cublasGemm* viene utilizzata insieme agli *streams*, il tempo di calcolo per eseguire i prodotti tra matrici dovrebbe ridursi notevolmente

- Nel caso della rete CUDA, eseguire una *cublasGemm* per stream su matrici relativamente piccole, sia per livelli convoluzionali che fully-connected, non ha portato a nessun miglioramento del tempo di calcolo

Implementazione della Rete

Stream

- Se la funzione *cublasGemm* viene utilizzata insieme agli *streams*, il tempo di calcolo per eseguire i prodotti tra matrici dovrebbe ridursi notevolmente

- Nel caso della rete CUDA, eseguire una *cublasGemm* per stream su matrici relativamente piccole, sia per livelli convoluzionali che fully-connected, non ha portato a nessun miglioramento del tempo di calcolo

- Il tempo impiegato con e senza stream è lo stesso, questo è dovuto al fatto che l'overhead della *cublasGemm* su diversi stream è maggiore dell'effettivo tempo di calcolo del prodotto matriciale

Implementazione della Rete

Rete Sequenziale

- Le accuratezze e i tempi di esecuzione della rete CUDA sono stati confrontati con quelli di una rete sequenziale chiamata *EduCNN*

Implementazione della Rete

Rete Sequenziale

- Le accuratezze e i tempi di esecuzione della rete CUDA sono stati confrontati con quelli di una rete sequenziale chiamata *EduCNN*

- La scelta della rete sequenziale è ricaduta sulla EduCNN perché consente di trovare buone accuratezze in un tempo adeguato

Implementazione della Rete

Rete Sequenziale

- Le accuratezze e i tempi di esecuzione della rete CUDA sono stati confrontati con quelli di una rete sequenziale chiamata *EduCNN*
- La scelta della rete sequenziale è ricaduta sulla EduCNN perché consente di trovare buone accuratezze in un tempo adeguato
- Ammette sia livelli di tipo fully-connected che convoluzionali

Implementazione della Rete

Rete Sequenziale

- Le accuratezze e i tempi di esecuzione della rete CUDA sono stati confrontati con quelli di una rete sequenziale chiamata *EduCNN*
- La scelta della rete sequenziale è ricaduta sulla EduCNN perché consente di trovare buone accuratezze in un tempo adeguato
- Ammette sia livelli di tipo fully-connected che convoluzionali
- L'unica funzione di attivazione implementata è la sigmoide

Implementazione della Rete

Rete Sequenziale

- Le accuratezze e i tempi di esecuzione della rete CUDA sono stati confrontati con quelli di una rete sequenziale chiamata *EduCNN*
- La scelta della rete sequenziale è ricaduta sulla EduCNN perché consente di trovare buone accuratezze in un tempo adeguato
- Ammette sia livelli di tipo fully-connected che convoluzionali
- L'unica funzione di attivazione implementata è la sigmoide
- La EduCNN è scritta con il linguaggio di programmazione *C++*

Implementazione della Rete

Differenze tra le due Reti

- Per ricavare i valori dei pesi iniziali, la EduCNN utilizza come generatore di numeri casuali l'algoritmo *xorshift128*

Implementazione della Rete

Differenze tra le due Reti

- Per ricavare i valori dei pesi iniziali, la EduCNN utilizza come generatore di numeri casuali l'algoritmo *xorshift128*

- Quando si definisce un livello, la EduCNN richiede all'utente di specificare il numero di livelli che vuole usare e la dimensione di output del livello precedente

Implementazione della Rete

Differenze tra le due Reti

- Per ricavare i valori dei pesi iniziali, la EduCNN utilizza come generatore di numeri casuali l'algoritmo *xorshift128*
- Quando si definisce un livello, la EduCNN richiede all'utente di specificare il numero di livelli che vuole usare e la dimensione di output del livello precedente
- La memoria allocata per ciascun livello deve essere eliminata dall'utente al termine dell'esecuzione del processo

Implementazione della Rete

Considerazioni

- I calcoli interni alla rete vengono svolti usando il formato di dato *double* per non perdere precisione numerica tra un passaggio e un altro

Implementazione della Rete

Considerazioni

- I calcoli interni alla rete vengono svolti usando il formato di dato *double* per non perdere precisione numerica tra un passaggio e un altro
- All'inizio della fase di training i pixel delle immagini vengono riscalati nell'intervallo $[0, 1]$ per poter essere compatibili con il formato di dato usato dalla rete

Implementazione della Rete

Configurazioni

- Il testing della rete viene effettuato combinando tra loro differenti tipi di livelli

Implementazione della Rete

Configurazioni

- Il testing della rete viene effettuato combinando tra loro differenti tipi di livelli
- Le diverse combinazioni vengono chiamate *Configurazioni*

Implementazione della Rete

Configurazioni

- Il testing della rete viene effettuato combinando tra loro differenti tipi di livelli
- Le diverse combinazioni vengono chiamate *Configurazioni*
- Vengono definite quattro configurazioni in modo da poter analizzare il comportamento della rete in determinate situazioni

Implementazione della Rete

Configurazioni

- Il learning rate η ed i pesi iniziali di ciascuna configurazione sono gli stessi per entrambe le reti

Implementazione della Rete

Configurazioni

- Il learning rate η ed i pesi iniziali di ciascuna configurazione sono gli stessi per entrambe le reti

- All'inizio della computazione, i pesi vengono posti ad un valore fisso di 0.001

Implementazione della Rete

Configurazioni

- Il learning rate η ed i pesi iniziali di ciascuna configurazione sono gli stessi per entrambe le reti
- All'inizio della computazione, i pesi vengono posti ad un valore fisso di 0.001
- Per alcune configurazioni, si è scelto di generare i pesi iniziali in maniera casuale in modo da poter valutare le differenti accuratezze ottenute dalle due reti

Implementazione della Rete

Configurazioni

- Il learning rate η ed i pesi iniziali di ciascuna configurazione sono gli stessi per entrambe le reti
- All'inizio della computazione, i pesi vengono posti ad un valore fisso di 0.001
- Per alcune configurazioni, si è scelto di generare i pesi iniziali in maniera casuale in modo da poter valutare le differenti accuratezze ottenute dalle due reti
- Il numero di nodi e di livelli per ciascuna configurazione viene scelto tenendo conto della componentistica hardware che si ha a disposizione per eseguire i test

Implementazione della Rete

Configurazioni

Livello	*Output*
Fully Connected	300×1
Fully Connected	10×1

Table: Configurazione 1

Livello	*Output*	*Dimensione Filtro*
Convoluzionale	24×24	$5 \times 5 \times 3$
Convoluzionale	20×20	$5 \times 5 \times 3$
Convoluzionale	16×16	$5 \times 5 \times 3$
Fully Connected	10×1	✗

Table: Configurazione 2

Implementazione della Rete

Configurazioni

Livello	*Output*	*Dimensione Filtro*
Convoluzionale	24×24	$5 \times 5 \times 3$
Fully Connected	400×1	✗
Convoluzionale	16×16	$5 \times 5 \times 3$
Fully Connected	10×1	✗

Table: Configurazione 3

Implementazione della Rete

Configurazioni

Livello	*Output*	*Dimensione Filtro*
Convoluzionale	24×24	$5 \times 5 \times 3$
Fully Connected	400×1	✗
Convoluzionale	16×16	$5 \times 5 \times 3$
Fully Connected	100×1	✗
Convoluzionale	6×6	$5 \times 5 \times 3$
Fully Connected	10×1	✗

Table: Configurazione 4

Implementazione della Rete

Configurazioni

- La *Configurazione 1* ha lo scopo di testare il comportamento della rete CUDA quando vengono utilizzati solo livelli di tipo fully-connected

Implementazione della Rete

Configurazioni

- La *Configurazione 1* ha lo scopo di testare il comportamento della rete CUDA quando vengono utilizzati solo livelli di tipo fully-connected

- La *Configurazione 2* verifica che mettendo più livelli convoluzionali in serie avviene il fenomeno dell'*overfitting*

Implementazione della Rete

Configurazioni

- La *Configurazione 1* ha lo scopo di testare il comportamento della rete CUDA quando vengono utilizzati solo livelli di tipo fully-connected

- La *Configurazione 2* verifica che mettendo più livelli convoluzionali in serie avviene il fenomeno dell'*overfitting*

- Le restanti configurazioni sono costruite alternado tra loro livelli convoluzionali di profondità tre e livelli fully-connected. Questo tipo di approccio serve a valutare se i valori di accuratezza ed i tempi di esecuzione ottenuti dalla rete CUDA sono validi anche per reti che ammettono una certa *profondità*

Analisi dei Risultati

Analisi dei Risultati

Hardware

- Le varie configurazioni sono state eseguite su due differenti tipi di macchine

Analisi dei Risultati

Hardware

- Le varie configurazioni sono state eseguite su due differenti tipi di macchine

- La prima presenta le seguenti caratteristiche tecniche

Analisi dei Risultati

Hardware

- Le varie configurazioni sono state eseguite su due differenti tipi di macchine

- La prima presenta le seguenti caratteristiche tecniche
  - Processore Intel Core i7-4510 da 2.00GHz

Analisi dei Risultati

Hardware

- Le varie configurazioni sono state eseguite su due differenti tipi di macchine
- La prima presenta le seguenti caratteristiche tecniche
  - Processore Intel Core i7-4510 da 2.00GHz
  - RAM da 6GB

Analisi dei Risultati

Hardware

- Le varie configurazioni sono state eseguite su due differenti tipi di macchine
- La prima presenta le seguenti caratteristiche tecniche
  - Processore Intel Core i7-4510 da 2.00GHz
  - RAM da 6GB
  - Scheda grafica Nvidia GeForce 820M da 1GB con Architettura Fermi

Analisi dei Risultati

Hardware

- Le varie configurazioni sono state eseguite su due differenti tipi di macchine
- La prima presenta le seguenti caratteristiche tecniche
  - Processore Intel Core i7-4510 da 2.00GHz
  - RAM da 6GB
  - Scheda grafica Nvidia GeForce 820M da 1GB con Architettura Fermi
  - Sistema operativo Ubuntu 17.10

Analisi dei Risultati

Hardware

- Le caratteristiche tecniche della seconda macchina sono

Analisi dei Risultati

Hardware

- Le caratteristiche tecniche della seconda macchina sono
  - Da Riempire come la slide precedente

Analisi dei Risultati

Parametri

- I diversi valori del learning rate η utilizzati per testare la rete sono stati ottenuti campionando l'intervallo $[0.001, 0.8]$ a step variabili

Analisi dei Risultati

Parametri

- I diversi valori del learning rate η utilizzati per testare la rete sono stati ottenuti campionando l'intervallo $[0.001, 0.8]$ a step variabili

- Per ciascuna configurazione vengono ricavati i tempi di computazione della rete sequenziale, della rete CUDA ed il relativo speedup

Analisi dei Risultati

Parametri

- I diversi valori del learning rate η utilizzati per testare la rete sono stati ottenuti campionando l'intervallo $[0.001, 0.8]$ a step variabili
- Per ciascuna configurazione vengono ricavati i tempi di computazione della rete sequenziale, della rete CUDA ed il relativo speedup
- Le configurazioni mostrate nei risultati sono quelle che hanno ottenuto il massimo valore di accuratezza in entrambe le reti tra tutti i learning rate η testati

Analisi dei Risultati

Risultati

Configurazione	η	*Rete*	*Accuratezza*	*Tempo [s]*	*Speedup*
1	0.09	EduCNN	30.50%	197	3.12
		CUDA	30.50%	63	
2	0.24	EduCNN	88.35%	184	2.60
		CUDA	88.35%	71	
3	0.62	EduCNN	93.80%	599	3.10
		CUDA	93.78%	193	
4	1.11	EduCNN	88.63%	680	3.16
		CUDA	92.17%	215	

Table: Risultati ottenuti eseguendo le configurazioni in ambiente Linux

Analisi dei Risultati

Risultati

Configurazione	η	*Rete*	*Accuratezza*	*Tempo [s]*	*Speedup*
1	0.56	EduCNN	97.60%	121	2.22
		CUDA	93.86%	55	
2	0.56	EduCNN	97.60%	121	2.22
		CUDA	93.86%	55	
3	0.62	EduCNN	93.80%	599	3.07
		CUDA	92.78%	195	
4	1.11	EduCNN	88.63%	680	3.1
		CUDA	92.10%	215	

Table: Risultati ottenuti eseguendo le configurazioni in ambiente Windows

Analisi dei Risultati

Risultati

Configurazione	η	*Rete*	*Accuratezza*	*Tempo [s]*	*Speedup*
1	0.09	EduCNN	92.18%	178	2.82
		CUDA	92.51%	63	
2	0.24	EduCNN	86.07%	193	2.7
		CUDA	80.57%	71	
3	0.62	EduCNN	94.32%	624	3.2
		CUDA	93.11%	195	
4	1.11	EduCNN	9.58%	649	3.16
		CUDA	9.58%	215	

Table: Risultati ottenuti eseguendo alcune delle configurazioni a partire da pesi iniziali generati casualmente in ambiente Linux

Analisi dei Risultati

Risultati

Configurazione	η	*Rete*	*Accuratezza*	*Tempo [s]*	*Speedup*
1	0.09	EduCNN	30.50%	197	3.12
		CUDA	30.50%	63	
2	0.24	EduCNN	88.35%	184	2.60
		CUDA	88.35%	71	
3	0.62	EduCNN	93.80%	599	3.10
		CUDA	93.78%	193	
4	1.11	EduCNN	88.63%	680	3.16
		CUDA	92.17%	215	

Table: Risultati ottenuti eseguendo alcune delle configurazioni a partire da pesi iniziali generati casualmente in ambiente Windows

Analisi dei Risultati

Analisi

- Da fare

Analisi dei Risultati

Analisi

- Da fare
- Da fare

Conclusioni

Conclusioni

Conclusioni

- Da fare

Conclusioni

Conclusioni

- Da fare

- Non dipende da librerie di terze parti e può essere eseguita anche sui sistemi operativi Windows e macOS